

Introduction aux modèles économétriques avec le Machine Learning

Agossou M. YOMAKOU

Mohammed VI Polytechnic University
The Faculty of Governance, Economics and Social Sciences

2025-03-24

1 Introduction

2 Big Data et Haute Dimensionnalité

3 P-normes

4 La régression Ridge

5 La régression Lasso

6 Elastic Net

7 Post-Lasso

8 Arbres de régression

9 Bagging

10 Forêts aléatoires

11 Assemblage

12 Double Selection Lasso

13 Post régularisation Lasso

14 Machine learning double/différencié

15 Appendice

16 Références

Introduction

- Ere des *Big Data*
- Une déluge de données nécessitant des méthodes automatisées d'analyse, ce que permet le Machine Learning.
- *Machine Learning, ensemble d'approches algorithmiques de la statistique.*
- Prédiction dans des contextes à structure inconnue et utilisation de grands échantillons.
- **Apprentissage supervisé, apprentissage non supervisé et classification.**
- Apprentissage supervisé, prédire Y à partir de X en haute dimension.
- Apprentissage non supervisé: découvrir des structures dans X .

Introduction

- Classification: analyser des choix discrets avec des prédicteurs en haute dimension.
- En économétrie, le Machine Learning est considéré comme hautement non paramétrique : estimer $m(X) = \mathbb{E}[Y \mid X]$ sans connaître la forme $m(X)$.
- L'analyse non paramétrique classique suppose que X est de faible dimension.
- Le Machine Learning autorise des centaines ou milliers de régresseurs sans information préalable sur leur pertinence.
- Des liens existent entre l'estimation non paramétrique, la sélection de modèles et le Machine Learning.

Big Data et Haute Dimensionnalité

- **Big Data:** Ensembles de données exceptionnellement volumineux et/ou complexes par rapport aux applications traditionnelles. Le stockage, la transmission et le calcul sont quelques uns des défis associés aux données volumineux.
- **Haute dimension:** Ensembles de données comportant un nombre anormalement élevé de variables. Il s'agit généralement de centaines ou de milliers de variables. La "haute dimensionnalité" est utilisée spécifiquement dans le contexte où $p \gg n$.
- Pour $p > n$, $X'X$ a un rang déficient, l'estimateur des MCO, $\hat{\beta}$ n'est pas identifiable.
- Pour $p < n$ mais "grand", la matrice $X'X$ peut être quasi-singulière ou mal conditionnée.
- L'estimateur des moindres carrés peut être numériquement instable et présenter une variance élevée.

P-normes

Pour un vecteur $a = (a_1, \dots, a_k)'$, la p-norme ($p \geq 1$) est:

$$\|a\|_p = \left(\sum_{j=1}^k |a_j|^p \right)^{1/p}.$$

■ la **norme 1**:

$$\|a\|_1 = \sum_{j=1}^k |a_j|,$$

■ la **norme 2** ou la **norme euclidienne**:

$$\|a\|_2 = \left(\sum_{j=1}^k |a_j|^2 \right)^{1/2}.$$

La régression Ridge

La régression ridge est un estimateur de type rétrécissement introduit par Hoerl et Kennard (1970). Les motivations sous-tendent l'utilisation de la régression ridge :

- réduire la collinéarité entre les variables explicatives
- résoudre des problèmes inverses de grande dimension ou mal posés.

Estimateur de la régression Ridge

$$\hat{\beta}_{ridge} = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p) \mathbf{X}'\mathbf{Y}$$

- $\lambda > 0$ est un paramètre de rétrécissement et doit être sélectionné avec précision.
- Cet estimateur est bien défini, même lorsque $p > n$.

La régression Ridge

- La constante λ est un paramètre de réglage.
- Elle résoud problème d'inversibilité, en utilisant la décomposition spectrale de $X'X$.

$X'X = H'DH$ où H est orthonormé et $D = \text{diag}\{r_1, \dots, r_p\}$ est une matrice diagonale avec les valeurs propres r_j de $X'X$ sur la diagonale.

$$X'X + \lambda I_p = H'DH + \lambda H'H = H'(D + \lambda)H$$

avec $\Lambda = \lambda I_p$ et des valeurs propres strictement positives $r_j + \lambda > 0$.

- Elles donc bornées par rapport à zéro, de sorte que $X'X + \lambda I_p$ soit de plien rang et bien conditionné.

La régression Ridge

Une autre perspective moderne repose sur la régularisation (Tikhonov 1943). Lorsque $X'X$ est mal conditionnée, son inversion devient problématique. La régularisation consiste à pénaliser les erreurs quadratiques en ajoutant une norme quadratique des coefficients au critère.

$$SSE_2(\beta, \lambda) = (Y - X\beta)'(Y - X\beta) + \lambda\beta'\beta = \|Y - X\beta\|_2^2 + \lambda\|\beta\|_2^2.$$

Le minimiseur de $SSE_2(\beta, \lambda)$ est l'estimateur des moindres carrés régularisé (pénalisé). Il équivaut à l'estimateur ridge $\hat{\beta}_{ridge}$. La pénalisation par λ empêche les coefficients d'atteindre des valeurs trop grandes, assurant ainsi une solution stable.

La régression Ridge

Une représentation duale du problème de minimisation régularisé est le problème contraint suivant:

$$\begin{array}{ll} \min_{\beta' \beta \leq \tau} & (Y - X\beta)'(Y - X\beta) \quad \text{avec } \tau > 0. \\ \text{st:} & \end{array}$$

Le Lagrangien du problème :

$L(\beta) = (Y - X\beta)'(Y - X\beta) + \lambda(\beta'\beta - \tau)$ où λ est le multiplicateur de lagrange.

La différence pratique entre les problèmes de pénalisation et de contrainte est que dans le premier cas, vous spécifiez le paramètre ridge λ alors que dans le second, vous spécifiez la contrainte τ . Ils sont liés puisque les valeurs λ et de τ satisfont la relation

$$Y'X(X'X + \lambda I_p)^{-1}(X'X + \lambda I_p)^{-1}X'Y = \tau.$$

Il suffit de résoudre (numériquement) l'équation pour trouver λ étant donné τ .

La régression Ridge




Figure 1: Solution de minimisation doublée de la régression ridge
L'estimateur ridge est obtenu à l'intersection de la contrainte sphérique et du contour des moindres carrés. La régression ridge suit une trajectoire influencée par la corrélation des variables.

Le “chemin de Ridge” représente l'évolution des coefficients lorsque λ varie de 0 à $+\infty$. Pour $\lambda = 0$, l'estimateur ridge coïncide avec les moindres carrés et se rapproche progressivement de l'origine à mesure que λ augmente.

La régression Ridge

Il est facile de généraliser la régression ridge pour autoriser différentes pénalités sur différents groupes de régresseurs. Prenons le modèle :

$$Y = X_1'\beta_1 + \cdots + X_G'\beta_G + e$$

et minimisons le *SSE* sous contrainte de la pénalité

$$\lambda_1\beta_1'\beta_1 + \cdots + \lambda_G\beta_G'\beta_G.$$

La solution est

$$\hat{\beta}_{ridge} = (\mathbf{X}'\mathbf{X} + \Lambda)^{-1} \mathbf{X}'\mathbf{Y} \quad \text{où} \quad \Lambda = \text{diag}\{\lambda_1 I_{p_1}, \cdots, \lambda_G I_{p_G}\}.$$

Cela permet une certaine flexibilité dans la pénalité des coefficients (plus ou moins que d'autres). En particulier:

- avec $\lambda_1 = 0$: un groupe de coefficients n'est donc pas pénalisé,
- avec $G = 2$, les coefficients sont répartis en deux groupes : pénalisés et non pénalisés.

La régression Ridge

L'estimateur de régression ridge leave-one-out, les erreurs de prédiction et le critère de validation croisée sont:

$$\begin{aligned}\hat{\beta}_{-i}(\lambda) &= \left(\sum_{j \neq i} X_j X_j' + \Lambda \right)^{-1} \left(\sum_{j \neq i} X_j Y_i \right) \\ \tilde{e}_i(\lambda) &= Y_i - X_i' \hat{\beta}_{-i}(\lambda) \\ CV(\lambda) &= \sum_{i=1}^n \tilde{e}_i(\lambda)^2.\end{aligned}$$

Le paramètre de ridge λ sélectionné par validation croisée, minimise $CV(\lambda)$. L'estimateur de ridge par validation croisée est calculé en utilisant $\hat{\lambda}$.

NB : En pratique, il peut être difficile de minimiser $CV(\lambda)$. Le minimum peut se produire à $\lambda = 0$, à $\lambda = +\infty$, ou il peut y avoir plusieurs minima locaux.

La régression Ridge

Theorem (29.1 BH Econ)

La prédiction des erreurs de régression ridge en validation croisée leave-one-out est

$$\tilde{e}_i(\lambda) = \left(1 - X_i' (\mathbf{X}'\mathbf{X} + \Lambda)^{-1} X_i\right)^{-1} \hat{e}_i(\lambda)$$

où $\hat{e}_i(\lambda) = Y_i - X_i' \hat{\beta}_{ridge}$ sont les résidus de la régression ridge.

Alternativement, la sélection de λ consiste à minimiser le critère de Mallows,

$$C(\lambda) = \sum_{i=1}^n \tilde{e}_i(\lambda) + 2\hat{\sigma}^2 \text{tr}((\mathbf{X}'\mathbf{X} + \Lambda)^{-1} (\mathbf{X}'\mathbf{X}))$$

où $\hat{\sigma}^2$ est l'estimateur de la variance issu des MCO.

La régression Ridge

En considérant un modèle de régression linéaire

$$Y = X'\beta + e$$

avec $\mathbb{E}[e \mid X] = 0$, nous avons,

$$\text{biais} [\hat{\beta}_{ridge} \mid \mathbf{X}] = -\lambda (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} \beta.$$

De plus avec un échantillon aléatoire,

$$\mathbb{V} [\hat{\beta}_{ridge} \mid \mathbf{X}] = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} (\mathbf{X}'\mathbf{D}\mathbf{X}) (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1}$$

où $\mathbf{D} = \text{diag}\{\sigma^2(X_1), \dots, \sigma^2(X_n)\}$ et $\sigma^2(x) = \mathbb{E}[e^2 \mid X]$.

Nous pouvons mesurer l'efficacité de l'estimation par la matrice de l'erreur quadratique moyenne (MSE),

$$\text{mse} [\hat{\beta} \mid \mathbf{X}] = \mathbb{E} [(\hat{\beta} - \beta)(\hat{\beta} - \beta)' \mid X].$$

La régression Ridge

Theorem (29.2 BH Econ)

Dans le modèle de régression linéaire, si $0 < \lambda < 2\sigma^2/\beta'\beta$,

$$mse \left[\hat{\beta}_{ridge} \mid \mathbf{X} \right] < mse \left[\hat{\beta}_{ols} \mid \mathbf{X} \right].$$

Ce théorème montre que l'estimateur ridge domine l'estimateur MCO sous certaines conditions. Cela est vrai quelle que soit la dimension de β . Étant donné que la borne supérieure $2\sigma^2/\beta'\beta$ est inconnue, il n'est cependant pas clair si une régression ridge réalisable domine les MCO.

La régression Ridge

- Estimateur de la variance de l'estimateur ridge, en utilisant l'analogie HC3

$$\tilde{V}_{\hat{\beta}} = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1} \left(\sum_{i=1}^n X_i X'_i \tilde{e}_i(\lambda)^2 \right) (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}$$

où $\tilde{e}_i(\lambda)$ sont les erreurs de prédiction de la régression ridge.

- Si les régresseurs sont hautement clairsemés, il est plus prudent d'utiliser l'estimateur homoscédastique

$$\tilde{V}_{\hat{\beta}}^0 = \tilde{\sigma}_i^2(\lambda) (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1} (\mathbf{X}'\mathbf{X}) (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}$$

avec $\tilde{\sigma}_i^2(\lambda) = n^{-1} \sum_{i=1}^n \tilde{e}_i(\lambda)^2$.

La régression Ridge

- L'estimateur ridge est explicitement biaisé, ce qui affecte l'interprétation des erreurs standard et des intervalles de confiance.
- Les intervalles de confiance classiques ont une couverture insuffisante en raison du biais.
- Une solution consiste à interpréter l'estimateur ridge comme en régression non paramétrique.
- Les estimateurs et intervalles de confiance sont valides pour les projections pseudo-vraies, $\beta^* = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}'\mathbf{X}\beta$.
- Pour une inférence asymptotiquement exacte sur les vrais coefficients, le paramètre ridge λ pourrait être sélectionné de manière à satisfaire $\lambda = o(\sqrt{n})$ de manière analogue à une bande passante de sous-lissage en régression non paramétrique.

La régression Ridge




Figure 2: Estimation des rendements de l'expérience par les moindres carrés et la régression ridge

La régression Lasso

La régression **Lasso (Least Absolute Shrinkage and Selection Operator)** proposée par Tibshirani (1996), est un cas de modèle de régression qui minimise la somme des erreurs quadratiques plus une pénalité en *norme 1*.

$$SSE_1(\beta, \lambda) = (Y - X\beta)'(Y - X\beta) + \lambda \sum_{j=1}^p |\beta_j| = \|Y - X\beta\|_2^2 + \lambda \|\beta\|_1^2$$

L'estimateur Lasso est le minimiseur de cette fonction

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} SSE_1(\beta, \lambda).$$

Le problème de minimisation du Lasso possède un problème de minimisation dual sous contrainte.

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\|\beta\|_1 \leq \tau} SSE_1(\beta, \lambda).$$

qui possède des conditions du premier ordre :

$$-2X_j'(Y - X\beta) + \text{sgn}(\beta_j) = 0$$

La régression Lasso




Figure 3: Solution de minimisation duale du Lasso

En général, le chemin de solution est linéaire par segments jusqu'à ce qu'un coefficient atteigne zéro, auquel cas ce coefficient est éliminé. Dans cet exemple particulier, le chemin de solution montre que β_2 augmente tandis que β_1 diminue. Ainsi, bien que Lasso soit un estimateur de rétrécissement, il ne réduit pas les coefficients individuellement de manière monotone.

La régression Lasso

Un cas où nous pouvons calculer explicitement les estimations Lasso est lorsque les régresseurs sont orthogonaux. Supposons que $X'X = I_p$. Alors, la condition du premier ordre pour la minimisation se simplifie en

$$-2 \left(\hat{\beta}_{\text{ols},j} - \hat{\beta}_{\text{Lasso},j} \right) + \lambda \text{sgn}(\hat{\beta}_{\text{Lasso},j}) = 0$$

qui a la solution explicite

$$\hat{\beta}_{\text{Lasso},j} = \begin{cases} \hat{\beta}_{\text{ols},j} - \lambda/2 & \text{si } \hat{\beta}_{\text{ols},j} > \lambda/2 \\ 0 & \text{si } |\hat{\beta}_{\text{ols},j}| \leq \lambda/2 \\ \hat{\beta}_{\text{ols},j} + \lambda/2 & \text{si } \hat{\beta}_{\text{ols},j} < -\lambda/2. \end{cases}$$

Cette estimation Lasso est une transformation continue de l'estimation des moindres carrés. Pour de petites valeurs de l'estimation des moindres carrés, l'estimation Lasso est fixée à zéro. Pour toutes les autres valeurs, l'estimation Lasso rapproche l'estimation des moindres carrés de zéro par un facteur $\lambda/2$.

La régression Lasso

Les estimateurs Lasso et ridge sont des fonctions continues.

- Tout comme la régression ridge, le Lasso n'est pas invariant à l'échelle des régresseurs. Si l'on redimensionne un régresseur, la pénalité prend un sens différent.
- Il est donc important de standardiser les régresseurs de manière appropriée avant d'appliquer le Lasso. Il est courant de mettre à l'échelle toutes les variables pour qu'elles aient une moyenne nulle et une variance unitaire.
- Le Lasso n'est également pas invariant aux rotations des régresseurs.

Par exemple, le Lasso sur (X_1, X_2) n'est pas le même que le Lasso sur $(X_1 - X_2, X_2)$ bien qu'ils aient des solutions des moindres carrés identiques. Cela est problématique car typiquement il n'existe pas de spécification par défaut.

La régression Lasso

- La pénalité λ joue un rôle clé dans l'estimation Lasso, influençant le nombre de variables sélectionnées.
- À mesure que λ augmente, le modèle devient plus parcimonieux en excluant davantage de variables.
- La validation croisée en K plis est la méthode standard pour choisir λ , avec $K = 10$ comme valeur par défaut.
- Minimiser le critère de validation croisée favorise une bonne précision de prévision, mais pas nécessairement une inférence précise.
- La règle "1se" sélectionne le modèle le plus parcimonieux parmi ceux proches du minimum du critère CV.
- Le critère CV est sensible à l'ordonnancement aléatoire des données, nécessitant une graine fixe pour la reproductibilité.

Elastic Net

Il s'agit d'un compromis entre la régression ridge et la régression Lasso. En prenant une moyenne pondérée des pénalités, on obtient le critère **Elastic Net** :

$$\text{SSE}(\beta, \lambda, \alpha) = (Y - X\beta)'(Y - X\beta) + \lambda \left(\alpha \|\beta\|_2^2 + (1 - \alpha) \|\beta\|_1 \right)$$

avec un poids α tel que $0 \leq \alpha \leq 1$.

- Pour de petites valeurs positives de λ_2 , les ensembles de contraintes ressemblent à des versions « arrondies » des ensembles de contraintes du Lasso.
- Les paramètres (α, λ) sont sélectionnés par minimisation conjointe du critère de validation croisée en K groupes.

Post-Lasso

L'estimateur **Lasso** sélectionne simultanément les variables et réduit les coefficients introduisant un biais dans l'estimation. Ce biais peut être réduit en appliquant la méthode des **moindres carrés après la sélection par Lasso** connu sous le nom d'**estimateur Post-Lasso**.

La procédure se déroule en **deux étapes** :

- 1 Estimer le modèle $Y = X\beta + e$ par **Lasso**, β_S
- 2 Estimer les coefficients β_S par **moindres carrés** :

$$\hat{\beta}_S = (X_S' X_S)^{-1} X_S' Y$$

avec X_S l'ensemble des variables dans X qui ont des coefficients non nuls dans $\hat{\beta}_{\text{Lasso}}$.

Cet estimateur est appelé **estimateur des moindres carrés Post-Lasso**.

- Belloni et Chernozhukov (2013) ont fourni des conditions sous lesquelles l'estimateur Post-Lasso **converge au même taux** que l'estimateur Lasso.
- L'estimateur **Post-Lasso** est un **estimateur de sélection post-modèle** ou un estimateur à **seuil dur**.
- L'estimateur Post-Lasso **équival exactement** à un estimateur de sélection, transformant les coefficients estimés par moindres carrés à l'aide d'une **fonction de seuil dur**, pour des **régresseurs sont orthogonales**.

Arbres de régression

- Introduits par *Breiman, Friedman, Olshen et Stone (1984)*, ils sont également connus sous l'acronyme **CART** (*Classification and Regression Trees*).
- Les arbres de régression peuvent être particulièrement utiles lorsqu'il y a une **combinaison de régresseurs continus et discrets**, rendant les méthodes traditionnelles de noyaux et de séries difficiles à appliquer.
- Les arbres de régression peuvent être vus comme **des splines d'ordre 0 avec des nœuds libres**.
- Ojectif : estimer la fonction de régression conditionnelle :

$$m(x) = \mathbb{E}[Y|X = x]$$

Métaphore de l'arbre

- 1 **Un sous-échantillon** est une **branche**.
- 2 **Les branches terminales** sont des **nœuds** ou **feuilles**.
- 3 **Ajouter des branches** est appelé **faire croître un arbre**.
- 4 Réduire le nombre de branches, c'est **élaguer** un arbre.

L'algorithme de base commence par une seule branche. Faites croître un arbre de grande taille en divisant les branches de manière séquentielle. Ensuite, élaguez-le en utilisant un critère d'information.

Arbres de régression

L'algorithme de croissance de base est le suivant. Les observations sont $\{Y_i, X_{1i}, \dots, X_{ki} : i = 1, \dots, n\}$.

- 1 Sélectionner une taille minimale de nœud $N_{\min}$. C'est le nombre minimal d'observations dans chaque feuille.
- 2 Appliquer séquentiellement les séparations d'échantillons de régression (slide suivant).

Après l'exécution de l'algorithme de croissance, la régression estimée est une fonction en escalier multidimensionnelle avec un grand nombre de branches et de feuilles.

Arbres de régression

- (a) Appliquer l'algorithme de séparation d'échantillons de régression pour diviser chaque branche en deux sous-branches, chacune ayant une taille d'au moins $N_{\min}$.
- (b) Sur chaque sous-branche b :
 - Calculer la moyenne empirique $\bar{b}$ de Y_i pour les observations de la sous-branche.
 - Ceci est l'estimateur de la fonction de régression sur cette sous-branche.
 - Les résidus sur la sous-branche sont $e_i = Y_i - \bar{b}$.
- (c) Sélectionner la branche dont la division réduit le plus la somme des erreurs quadratiques.
- (d) Diviser cette branche en deux branches. Ne faire aucune autre division.
- (e) Répéter les étapes (a)-(d) jusqu'à ce qu'aucune branche ne puisse être divisée davantage. Les branches terminales (non divisées) sont les feuilles.

Arbres de régression

L'algorithme de réduction (pruning) de base est le suivant :

- 1 Définir le critère d'information de type Mallows :

$$C = \sum_{i=1}^n \hat{e}_i^2 + \alpha N$$

où N est le nombre de feuilles et α est un paramètre de pénalisation.

- 2 Calculer le critère C pour l'arbre actuel.
- 3 Appliquer une régression pas à pas (*backward stepwise regression*) pour réduire le nombre de feuilles.
 - (a) Identifier la feuille dont la suppression diminue le plus C .
 - (b) Tailler (supprimer) cette feuille.
 - (c) Si aucune feuille ne réduit C lorsqu'elle est supprimée, arrêter la réduction.
 - (d) Sinon, répéter les étapes (a)-(c).

Arbres de régression

- L'avantage des arbres de régression est qu'ils offrent une approximation non paramétrique très flexible.
- Leur principale utilisation est la prédiction.
- Un inconvénient des arbres de régression est que les résultats sont difficiles à interpréter, car il n'y a pas de coefficients de régression.
- Un autre inconvénient est que la régression ajustée $m(x)$ est une fonction en escalier discrète, ce qui peut être une approximation grossière lorsque $m(x)$ est continue et lisse.
- Pour obtenir une bonne approximation, un arbre de régression peut nécessiter un grand nombre de feuilles, ce qui peut entraîner une variance d'estimation élevée.

Bagging

- Le bagging (*bootstrap aggregating*) a été introduit par Breiman (1996) pour réduire la variance d'un prédicteur.
- L'idée de base est simple : générer un grand nombre B d'échantillons bootstrap, prendre la moyenne des estimations des régressions sur chaque échantillon bootstrap.
- La moyenne des estimations bootstrap constitue l'*estimateur par bagging de la moyenne conditionnelle*.
- Le bagging est considéré comme utile lorsque l'estimateur de la moyenne conditionnelle présente un faible biais mais une forte variance, comme les estimateurs avec seuils durs (arbres de régression, modèles de sélection et le post-Lasso).
- Le bagging agit comme une opération de lissage qui réduit la variance, qui pourrait aussi amplifier le biais dans le cas où il est élevé.

Bagging

- Soit $m(x) = E[Y|X = x]$ et $\hat{m}(x)$ un estimateur, tel qu'un arbre de régression. Soit $\hat{m}_b^*(x)$ le même estimateur construit sur un échantillon bootstrap. L'estimateur par bagging de $m(x)$ est donné par : $\hat{m}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{m}_b^*(x)$.
- Lorsque B augmente, cet estimateur converge en probabilité bootstrap vers l'estimateur idéal par bagging $\mathbb{E}[\hat{m}^*(x)]$.
- L'estimateur de sélection $\hat{\theta}_{\text{pms}} = h(\hat{\theta})$ est la transformation en seuil dur $h(t)$ appliquée à $\hat{\theta}$, l'estimateur par bagging $\hat{\theta}_{\text{bag}} = g(\hat{\theta})$ est la transformation lissée $g(t)$ appliquée à $\hat{\theta}$.
- L'application la plus courante du bagging concerne les arbres de régression. Les arbres ont une structure similaire à notre estimateur de sélection $\hat{\theta}_{\text{pms}}$ et devraient donc entraîner une réduction de l'EQM par rapport à l'estimation par arbre de régression.

Bagging

- Un sous-produit pratique du bagging est un proxy de validation croisée appelé erreur de prédiction hors échantillon (**out-of-bag, OOB**).
- Un échantillon bootstrap non paramétrique typique contient environ 63% des observations initiales, ce qui signifie qu'environ 37% des observations ne sont pas présentes dans cet échantillon bootstrap.
- Ainsi, une estimation bootstrap de la fonction de régression $m(x)$ construite sur cet échantillon a “laissé de côté” environ 37% des observations.
- L'estimateur « leave i out » du bagging, $\hat{m}_{-i}(x)$, de $m(x)$ est obtenu en moyennant uniquement sur ce second ensemble (les 37% qui excluent l'observation).
- L'erreur hors échantillon est alors $\tilde{e}_i = Y_i - \hat{m}_{-i}(X_i)$. Le CV croisée hors échantillon est $\sum_{i=1}^n \tilde{e}_i^2$. Celui-ci peut être utilisé comme estimateur de l'EQMP hors échantillon.

Bagging

Wager, Hastie et Efron (2014) proposent des estimateurs de $V_n(x) = \text{var}(\hat{m}_{\text{bag}}(x))$. Soit N_{ib} le nombre de fois où l'observation i apparaît dans l'échantillon bootstrap b , et $N_i = \frac{1}{B} \sum_{b=1}^B N_{ib}$.

L'estimateur **jackknife infinitésimal** (EJI) de V_n

$$\hat{V}_n(x) = \sum_{i=1}^n \text{cov}^* (N_i, \hat{m}_{\text{bag}}(x))^2$$
$$\hat{V}_n(x) = \sum_{i=1}^n \left[\frac{1}{B} \sum_{b=1}^B (N_{ib} - N_i)(m_b(x) - m_{\text{bag}}(x)) \right]^2. \quad (\text{EJI})$$

Cet estimateur de variance est basé sur Efron (2014).

Forêts aléatoires

Les forêts aléatoires, introduites par Breiman (2001), sont une modification des arbres de régression avec bagging. Cette modification vise à réduire la variance de l'estimation. Les forêts aléatoires sont populaires dans les applications de Machine Learning et ont largement remplacé les arbres de régression simples.

- Conditionnellement à l'échantillon, les arbres de régression issus du bootstrap sont positivement corrélés.
- Cette corrélation entraîne une variance élevée de la moyenne des arbres bootstrap.
- La modification apportée par les forêts aléatoires consiste à **décorrél**er les arbres de régression bootstrap en introduisant une **randomisation supplémentaire**.
- Cette décorrélation réduit la variance de la moyenne bootstrap et, par conséquent, son EQM.

Forêts aléatoires

L'algorithme de base des forêts aléatoires est le suivant

- 1 Choisissez une taille minimale de feuille $N_{\min}$ (par défaut 5), une fraction minimale de division, $\alpha \in [0, 1]$, et un nombre d'échantillonnage m parmi p (par défaut $p/3$).
- 2 Pour $b = 1, \dots, B$:
 - (a) Tirer un échantillon bootstrap non paramétrique.
 - (b) Faire croître un arbre de régression comme suit :
 - i. Sélectionner m var. aléatoirement parmi les p régresseurs.
 - ii. Choisir la variable optimale pour la division tout en garantissant que chaque sous-échantillon contient au moins $N_{\min}$ observations et une fraction minimale de la branche.
 - iii. Diviser l'échantillon bootstrap en conséquence.
 - (c) Arrêter lorsque chaque feuille contient entre $N_{\min}$ et $2N_{\min} - 1$ observations.
 - (d) Définir $\hat{m}_b(x)$ comme la moyenne empirique de Y sur chaque feuille de l'arbre bootstrap.
- 3 Calculer $\hat{m}_{\text{rf}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{m}_b(x)$.

Forêts aléatoires

- L'utilisation de la randomisation pour réduire le nombre de variables de p à m à chaque étape modifie la structure de l'arbre, ce qui réduit la corrélation entre les arbres de régression issus du bootstrap.
- Cette réduction de la corrélation diminue la variance de la moyenne bootstrap.
- L'estimateur du jackknife infinitésimal (EJI) peut être utilisé pour estimer la variance et l'erreur standard.
- Une variante proposée par Wager et Athey (2018) consiste à utiliser des **arbres "honnêtes"** pour supprimer la dépendance entre les divisions de l'échantillon et les moyennes d'échantillon.

Forêts aléatoires

La consistance et la normalité asymptotique ont été établies par Wager et Athey (2018). Ils supposent que la moyenne conditionnelle et la variance sont continues de Lipschitz en x , que $X \sim U[0, 1]^p$ et que p est fixé. Ils supposent également que la forêt aléatoire est construite par sous-échantillonnage, estimée à l'aide d'arbres honnêtes, et que la fraction minimale de division satisfait $0 < \alpha \leq 0.2$.

Sous ces conditions, ils établissent que, ponctuellement en x ,

Distribution asymptotique

$$\frac{\hat{m}_{\text{rf}}(x) - m(x)}{\sqrt{V_n(x)}} \xrightarrow{d} \mathcal{N}(0, 1),$$

Assemblage

- L'**assemblage** est le terme utilisé en Machine learning pour désigner l'**agrégation de modèles** à travers plusieurs algorithmes de Machine learning.
- Supposons que vous disposiez d'un ensemble d'estimateurs: ACP, régression à noyau, régression en séries, régression ridge, Lasso, arbre de régression, etc.
- Le principe de l'**agrégation de modèles** suggère qu'il est possible d'obtenir de meilleures performances en prenant une moyenne pondérée plutôt qu'en sélectionnant un seul modèle.
- L'**assemblage** en Machine learning peut utiliser bon nombre de ces mêmes méthodes. La plus populaire est le **stacking**, identique à l'**agrégation de modèles Jackknife**.
- Cette méthode sélectionne les poids d'agrégation des modèles en minimisant un critère de validation croisée, sous la contrainte que $\sum_i w_i = 1$ avec $w_i \geq 0$.

Double Selection Lasso

- L'inférence post-estimation est difficile avec la plupart des estimateurs de Machine Learning.
- Considérons le modèle linéaire :

$$Y = D\theta + X'\beta + e \quad (1)$$

$\mathbb{E}[e \mid D, X] = 0$ où Y et D sont scalaires et X est un vecteur $p \times 1$.

- La variable D est l'objet principal de l'étude, tandis que X représente les variables de contrôle. L'objectif est d'inférer sur θ .

Belloni, Chernozhukov et Hansen (2014b) montrent qu'une meilleure précision de la couverture peut être obtenue si X est inclus dans la régression (1) dès lors qu'il est corrélé à D .

Double Selection Lasso

Cela conduit à la stratégie dite de **double sélection**. On commence par spécifier une équation auxiliaire pour D :

$$D = X'\gamma + V \quad (2)$$

$$\mathbb{E}[V \mid X] = 0$$

On peut écrire une forme réduite pour Y :

$$Y = X'\eta + U \quad (3)$$

$$\mathbb{E}[U \mid X] = 0 \text{ où } \eta = \beta + \gamma\theta \text{ et } U = e + V\theta$$

L'algorithme de double sélection proposé applique la sélection de modèle séparément aux équations (2) et (3), prend l'union des régresseurs sélectionnés, puis estime l'équation (1) par MCO en utilisant ces régresseurs. Cette méthode garantit qu'une variable X est incluse si elle est pertinente pour la régression (1) ou si elle est corrélée avec D .

Double Selection Lasso

L'algorithme **double-selection** recommandé par Belloni, Chernozhukov et Hansen (2014b) suit ces étapes :

- 1 Estimer l'équation auxiliaire (2) par Lasso et noter X_1 les variables sélectionnées.
- 2 Estimer l'équation réduite (3) par Lasso et noter X_2 les variables sélectionnées.
- 3 Définir $\tilde{X} = X_1 \cup X_2$, soit l'union des variables sélectionnées dans les deux équations.
- 4 Réaliser une régression de Y sur $(D, \tilde{X})$ pour obtenir l'estimateur **double-selection** $\hat{\theta}_{DS}$.
- 5 Calculer une erreur standard robuste à l'hétéroscédasticité pour $\hat{\theta}_{DS}$.

Double Selection Lasso

- Belloni, Chernozhukov et Hansen (2014b) montrent que sous une structure de parcimonie approximative, l'estimateur $\hat{\theta}_{DS}$ est **asymptotiquement normal**, et son **t-ratio** suit une loi normale standard.
- Les méthodes d'inférence conventionnelles sont donc valides.
- L'idée clé est que la sélection via Lasso dans les deux équations garantit que toutes les variables pertinentes sont incluses, évitant ainsi le biais de sélection.
- L'avantage principal de l'estimateur de double sélection réside dans sa simplicité et sa structure intuitive claire.

Post régularisation Lasso

Une amélioration potentielle du Lasso à double sélection est l'estimateur de Lasso post-régularisation proposé par Chernozhukov, Hansen et Spindler (2015).

Nous commençons par transformer l'équation structurelle (1) afin d'éliminer la composante de grande dimension.

$$Y - \mathbb{E}[Y | X] = (D - \mathbb{E}[D | X])\theta + e.$$

Cette transformation élimine le régresseur X ainsi que le coefficient de grande dimension β . Les modèles (2) et (3) spécifient $\mathbb{E}[Y | X]$ et $\mathbb{E}[D | X]$ comme des fonctions linéaires de X .

Nous obtenons :

$$Y - X'\eta = (D - X'\gamma)\theta + e. \tag{4}$$

Post régularisation Lasso

Si η et γ étaient connus, le coefficient θ pourrait être estimé par MCO. Etant inconnus, ils doivent être estimés.

L'estimateur recommandé par Chernozhukov, Hansen et Spindler (2015) est le suivant :

- 1 **Estimation de (2) par Lasso ou post-Lasso** avec le paramètre de Lasso λ_1 . Soit $\hat{\gamma}$ l'estimateur des coefficients et $\hat{V}_i = D_i - X_i' \hat{\gamma}$ le résidu.
- 2 **Estimation de (3) par Lasso ou post-Lasso** avec le paramètre de Lasso λ_2 . Soit $\hat{\eta}$ l'estimateur des coefficients et $\hat{U}_i = Y_i - X_i' \hat{\eta}$ le résidu.
- 3 **Estimation finale** : Soit $\hat{\theta}_{PR}$ le coefficient des MCO de la régression de $\hat{U}$ sur $\hat{V}$.
- 4 **Calcul de l'erreur standard** : Une erreur standard conventionnelle (hétéroscédastique) est calculée pour $\hat{\theta}_{PR}$.

Post régularisation Lasso

- La condition de moment pour θ , basée sur l'équation (1), est :

$$m(\theta, \beta) = \mathbb{E}[D(Y - D\theta - X'\beta)] = 0.$$

- Sa sensibilité par rapport à β est donnée par sa dérivée évaluée aux vrais coefficients, qui est non nul lorsque D et X sont corrélés.
- L'inclusion ou l'exclusion de la variable X a un impact sur la condition de moment pour θ et donc sur sa solution.
- En revanche, la condition de moment pour θ basée sur l'équation (4) est :

$$m_{PR}(\mu, \beta) = \mathbb{E}[(D - X'\gamma)(Y - X'\eta - (D - X'\gamma)\theta)]$$

$$m_{PR}(\mu, \beta) = \mathbb{E}[(D - X'\gamma)(Y - D\theta - X'\beta)].$$

- Sa sensibilité par rapport à β est égale à zéro et est donc non corrélé avec X .

Post régularisation Lasso

Puisque la sensibilité de $m_{PR}(\theta, \beta)$ par rapport à β est nulle, l'inclusion ou l'exclusion de la variable X a seulement un impact faible sur la condition de moment pour μ et sur son estimateur.

Sous des hypothèses données, on a le résultat suivant:

Distribution asymptotique

$$\sqrt{n}(\hat{\theta}_{PR} - \theta) \xrightarrow{d} N\left(0, \frac{\mathbb{E}[V^2 e^2]}{\mathbb{E}[V^2]^2}\right).$$

De plus, l'estimateur de variance standard pour $\hat{\theta}_{PR}$ est convergent pour la variance asymptotique.

Post régularisation Lasso

- L'avantage de l'estimateur post-régularisation $\hat{\theta}_{PR}$ par rapport à l'estimateur à double sélection $\hat{\theta}_{DS}$ est *l'efficacité*.
- L'estimateur post-régularisation utilise uniquement les composantes pertinentes de X pour centrer séparément Y , D .
- L'estimateur post-régularisation permet de distinguer ces effets et de les estimer séparément.
- L'estimateur à double sélection utilise l'union des deux ensembles de régresseurs pour estimer θ , ce qui entraîne une spécification *moins parcimonieuse*.
- Un avantage de l'estimateur à double sélection est *la réduction du biais et une meilleure robustesse*.

Machine learning double/différencié

La contribution la plus récente aux méthodes d'inférence pour le modèle (1) est l'estimateur **Double/Debiased Machine Learning (DML)** de Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey et Robins (2018)

- L'estimateur **DML** étend l'estimateur de *post-régularisation* présenté dans la section précédente en ajoutant une *technique de partitionnement des échantillons*, similaire à l'estimateur *IV à échantillons séparés*.
- Les auteurs soutiennent que cela *réduit la dépendance entre les étapes d'estimation* et peut *améliorer les performances*.
- L'estimateur de post-régularisation commence par estimer les coefficients des modèles (2) et (3), puis estime le coefficient θ .
- L'estimateur **à échantillons séparés** effectue ces étapes d'estimation en utilisant **des échantillons distincts**.
- L'estimateur **DML** va encore plus loin en utilisant une *partition en K sous-échantillons* (*K -fold partitioning*).

Machine learning double/différencié

L'algorithme d'estimation est le suivant.

- 1 Diviser aléatoirement l'échantillon en K sous-échantillons indépendants $A_k, k = 1, \dots, K$, d'environ même taille n/K .
- 2 Écrire les matrices de données pour chaque sous-échantillon sous la forme (Y_k, D_k, X_k) .
- 3 Pour chaque $k = 1, \dots, K$:
 - a) Utiliser toutes les observations sauf celles du sous-échantillon k pour estimer les coefficients θ et γ dans les équations (2) et (4) à l'aide de *Lasso* ou *post-Lasso*. Ces estimateurs exclus du pli k sont notés $\hat{\gamma}_{-k}$ et $\hat{\eta}_{-k}$.
 - b) Calculer $\hat{V}_k = D_k - X_k \hat{\gamma}_{-k}$ et $\hat{U}_k = Y_k - X_k \hat{\eta}_{-k}$.
- 4 Estimer $\hat{\theta}_{\text{DML}}$:
$$\hat{\theta}_{\text{DML}} = \left(\sum_{k=1}^K \hat{V}_k' \hat{V}_k \right)^{-1} \left(\sum_{k=1}^K \hat{V}_k' \hat{U}_k \right)$$
$$\hat{\theta}_{\text{DML}} = (\hat{V}' \hat{V})^{-1} (\hat{V}' \hat{U})$$
- 5 Construire une erreur standard classique (hétéroscédastique) pour $\hat{\theta}_{\text{DML}}$.

Machine learning double/différencié

- L'avantage de l'estimateur DML par rapport à l'estimateur post-régularisation est que la séparation de l'échantillon élimine la dépendance entre les deux étapes d'estimation, réduisant ainsi le biais lié à la sélection post-modèle.
- L'estimateur est aléatoire en raison de la séparation de l'échantillon.
- Deux chercheurs travaillant avec le même ensemble de données, mais effectuant des séparations aléatoires différentes, obtiendront deux estimateurs distincts.
- L'estimation de γ et η est effectuée sur des échantillons plus petits, ce qui réduit l'efficacité de l'estimation. Cependant, cet effet reste mineur si $K \geq 10$.

Quoi qu'il en soit, ces considérations suggèrent que le DML peut être particulièrement approprié dans des contextes où n est grand et $K \geq 10$.

Appendice

<i>Function class $\mathcal{F}$ (and its parametrization)</i>	<i>Regularizer $R(f)$</i>
Global/parametric predictors	
Linear $\beta'x$ (and generalizations)	Subset selection $\ \beta\ _0 = \sum_{j=1}^k 1_{\beta_j \neq 0}$ LASSO $\ \beta\ _1 = \sum_{j=1}^k \beta_j $ Ridge $\ \beta\ _2^2 = \sum_{j=1}^k \beta_j^2$ Elastic net $\alpha \ \beta\ _1 + (1 - \alpha) \ \beta\ _2^2$
Local/nonparametric predictors	
Decision/regression trees	Depth, number of nodes/leaves, minimal leaf size, information gain at splits
Random forest (linear combination of trees)	Number of trees, number of variables used in each tree, size of bootstrap sample, complexity of trees (see above)
Nearest neighbors	Number of neighbors
Kernel regression	Kernel bandwidth
Mixed predictors	
Deep learning, neural nets, convolutional neural networks	Number of levels, number of neurons per level, connectivity between neurons
Splines	Number of knots, order
Combined predictors	
Bagging: unweighted average of predictors from bootstrap draws	Number of draws, size of bootstrap samples (and individual regularization parameters)
Boosting: linear combination of predictions of residual	Learning rate, number of iterations (and individual regularization parameters)
Ensemble: weighted combination of different predictors	Ensemble weights (and individual regularization parameters)

Références

- 1). Charpentier, A., Flachaire, E. & Ly, A. (2018). Econometrics and Machine Learning. *Economie et Statistique / Economics and Statistics*, 505-506, 147–169.
- 2). Hansen, B. E. (2022). Econometrics. Madison, WI: University of Wisconsin.
- 3). Kevin P. Murphy. (2012). Machine Learning: A probabilistic Perspective: Massachusetts Institute of Technology.
- 4). Victor Chernozhukov, Christian Hansen, Martin Spindler. Valid Post-Selection and Post-Regularization Inference: An Elementary, General Approach. *Annual Review of Economics*, Vol. 7: 649-688 (August 2015). arXiv:1501.03430

Vous pouvez accéder à mon Notebook pour ce cours sur mon répertoire GitHub, ainsi qu'à d'autres ressources complémentaires pour approfondir le sujet. [link](#)

Merci pour l'attention !!!

