

Notebook

Introduction aux modèles économétriques avec du Machine Learning

Agossou M. YOMAKOU

2025-05-08



University
Mohammed VI
Polytechnic



FACULTÉ DE GOUVERNANCE,
SCIENCES ECONOMIQUES ET SOCIALES

Contents

Introduction and Overview	3
1 Big Data, Haute Dimensionnalité et Machine Learning	3
2 Régression à haute dimension	4
3 P-normes	5
4 La régression Ridge	6
5 La régression Lasso	10
6 Elastic Net	12
7 Post-Lasso	13
8 Arbres de régression	13
9 Bagging	15
10 Forêts aléatoires	17
11 Assemblage	18
12 Double Sélection Lasso	19
13 Post régularisation Lasso	20
14 Machine learning double/différencié	21
15 liste de package	23
16 Appendice	24
17 Références	25

Introduction and Overview

Nous sommes dans l'ère des Big data. Par exemple, il y a environ 40 milliards de pages web indexées ; 100 heures de vidéo sont téléchargées sur YouTube chaque minute ; les génomes de milliers de personnes, dont chacun a une longueur de $3,8 \cdot 10^9$ paires de bases, ont été séquencés par différents laboratoires.

Ce déluge de données nécessite des méthodes automatisées d'analyse des données, ce que permet le Machine Learning. En particulier, nous définissons l'apprentissage automatique comme un ensemble de méthodes capables de détecter automatiquement des schémas dans les données, puis d'utiliser les schémas découverts pour prédire les données futures ou pour prendre d'autres types de décisions dans des conditions d'incertitude. L'apprentissage automatique est généralement divisé en deux types principaux. Dans l'approche prédictive ou d'apprentissage supervisé, l'objectif est d'apprendre une correspondance entre les entrées x et les sorties y , étant donné un ensemble étiqueté de paires entrée-sortie $\mathcal{D} = \{(x_i; y_i)\}_{i=1}^N$. Ici, $\mathcal{D}$ est appelé l'ensemble d'apprentissage et N est le nombre d'exemples d'apprentissage. La forme de la sortie ou **variable de réponse** peut en principe être quelconque, mais la plupart des méthodes supposent que y_i est une variable **catégorielle** ou **nominale** d'un ensemble fini, $y_i \in \{1, \dots, C\}$, ou y_i est un scalaire à valeur réelle. Lorsque y_i est catégorique, le problème est appelé **classification** ou **reconnaissance de patrons**, et lorsque y_i est à valeurs réelles, le problème est appelé **régression**.

Le deuxième grand type d'apprentissage automatique est l'approche **descriptive** ou **d'apprentissage non supervisé**. Dans ce cas, nous ne recevons que des données d'entrée, $\mathcal{D} = \{x_i\}_{i=1}^N$, et l'objectif est de trouver des « modèles intéressants » dans les données. C'est ce que l'on appelle parfois la **découverte de connaissances**. Il s'agit d'un problème beaucoup moins bien défini, car on ne nous dit pas quels types de modèles rechercher, et il n'y a pas de mesure d'erreur évidente à utiliser (contrairement à l'apprentissage supervisé, où l'on peut comparer notre prédiction de y pour un x donné à la valeur observée).

Une référence classique est Hastie, Tibshirani et Friedman (2008). Les manuels d'introduction comprennent James, Witten, Hastie et Tibshirani (2013) et Efron et Hastie (2017). Pour les traitements théoriques, voir Bühlmann et van der Geer (2011). Pour une analyse de l'apprentissage automatique en économétrie, voir Belloni, Chernozhukov et Hansen (2014a), Belloni, Chernozhukov et Hansen (2014b), Mullainathan et Spiess (2017), Athey et Imbens (2019), et Belloni, Chernozhukov, Chetverikov, Hansen et Kato (2021).

1 Big Data, Haute Dimensionnalité et Machine Learning

- **Big Data**

Généralement utilisé pour décrire des ensembles de données exceptionnellement volumineux et/ou complexes par rapport aux applications traditionnelles. La définition du terme “*grand*” varie selon la discipline et l'époque, mais il s'agit généralement d'ensembles de données comportant de millions de d'observations. Ces ensembles peuvent provenir, en économie, des données de recensement des ménages, des dossiers administratifs des gouvernements et des données des scanners des supermarchés. Le stockage, la transmission et le calcul sont quelques uns des défis associés aux données volumineuses.

- **Haute dimension**

Généralement utilisée pour décrire des ensembles de données comportant un nombre anormalement élevé de variables. Là encore la définition de “*grand*” varie d'une application à l'autre, mais il s'agit généralement de centaines ou de milliers de variables. Dans la littérature, la “haute dimensionnalité” est utilisée spécifiquement dans le contexte où $p \gg n$, ce qui signifie que le nombre de variables p dépasse largement le nombre d'observations n .

- **Machine learning**

Généralement utilisé pour décrire un ensemble d’approches algorithmiques de la statistique. Les méthodes sont principalement axées sur la prédiction de points dans des contextes et dont la structure est inconnue. Les méthodes de Machine Learning ou d’apprentissage automatique permettent également d’utiliser des échantillons de grande taille, et un nombre de variables et une forme structurelle inconnue. Le machine learning englobe un ensemble large et diversifié d’outils pour une variété de contextes, y compris l’**apprentissage supervisé** (règle de prédiction pour Y étant donné X en haute dimension), l’**apprentissage non supervisé** (découverte de la structure parmi X en haute dimension) et la **classification** (analyse de choix discret avec des prédicteurs en haute dimension).

Dans le cadre de ce cours, nous nous concentrerons sur l’apprentissage supervisé, car il s’agit d’une extension naturelle de la régression linéaire.

En économétrie, le Machine learning peut être considéré comme “*hautement non paramétrique*”. Supposons que nous soyons intéressés par l’estimation de la moyenne conditionnelle $m(X) = \mathbb{E}[Y | X]$ lorsque la forme de $m(X)$ est inconnue. L’analyse non paramétrique suppose généralement que X est de faible dimension. En revanche, le Machine learning peut autoriser des centaines, voire des milliers de régresseurs dans X et ne nécessite pas d’informations préalables sur les régresseurs les plus pertinents. Des liens entre l’estimation non paramétrique, la sélection de modèles et les méthodes de Machine learning apparaissent lors de la sélection des paramètres par validation croisée et de l’évaluation par accurté de prédiction hors échantillon.

2 Régression à haute dimension

Nous connaissons le modèle de régression linéaire $Y = X\beta + e$, où X et β sont des vecteurs $p \times 1$. Dans les modèles de régression conventionnels, nous avons l’habitude de considérer que le nombre de variables p est petit par rapport à la taille de l’échantillon n . La théorie asymptotique paramétrique traditionnelle suppose que p est fixe lorsque $n \rightarrow \infty$, ce qui est généralement interprété comme impliquant que p est beaucoup plus petit que n .

La régression non paramétrique suppose généralement que $p \rightarrow \infty$ mais à un rythme beaucoup plus lent que n . Cela est interprété comme signifiant que p est modérément grand mais toujours beaucoup plus petit que n . **La régression à haute dimension** est utilisée pour décrire le contexte où p est très grand, y compris le cas où p est plus grand que n . Elle comprend même le cas où p est exponentiellement plus grand que n .

Il peut sembler choquant d’envisager une application comportant plus de régresseurs que d’observations. Mais cette situation se présente dans un certain nombre de contextes.

De nombreuses applications économiques impliquent un grand nombre de variables binaires, discrètes et catégorielles. Un modèle de régression saturé convertit toutes les variables discrètes et catégorielles en variables binaires et inclut toutes les interactions. De telles manipulations peuvent aboutir à des milliers de régresseurs. Par exemple, dix variables binaires en interaction complète donnent 1024 régresseurs. Vingt variables binaires en interaction totale donnent plus d’un million de régresseurs.

De nombreux “grands” ensembles de données contemporains contiennent des milliers de régresseurs potentiels. De nombreuses variables peuvent être peu informatives, mais il est difficile de savoir *a priori* lesquelles sont pertinentes et lesquelles ne le sont pas.

Lorsque $p > n$, l’estimateur des moindres carrés $\hat{\beta}$ n’est pas défini de manière unique puisque $X^\top X$ a un rang déficient. En outre, pour $p < n$ mais “grand”, la matrice $X^\top X$ peut être quasi-singulière ou mal conditionnée, de sorte que l’estimateur des moindres carrés peut être numériquement instable et présenter une variance élevée.

Par conséquent, nous nous tournons vers des méthodes d’estimation autres que les moindres carrés. Dans ce chapitre, nous examinons plusieurs méthodes d’estimation alternatives, notamment: *la régression ridge, le Lasso, le filet élastique, les arbres de régression et les forêts aléatoires*.

3 P-normes

Pour un vecteur $a = (a_1, \dots, a_k)'$, la p-norme ($p \geq 1$) est:

$$\|a\|_p = \left(\sum_{j=1}^k |a_j|^p \right)^{1/p}.$$

Parmi les cas particuliers important, on peut citer:

- la **norme 1**

$$\|a\|_1 = \sum_{j=1}^k |a_j|,$$

- la **norme 2** ou la **norme euclidienne**

$$\|a\|_2 = \left(\sum_{j=1}^k |a_j|^2 \right)^{1/2},$$

- la **norme infini**

$$\|a\|_\infty = \max_{1 \leq j \leq k} |a_j|.$$

Nous allons également définir la **norme 0**

$$\|a\|_0 = \sum_{j=1}^k 1\{a_j \neq 0\},$$

le nombre d'éléments non nuls.

La norme p satisfait la propriété additive suivante: Si $a = (a_0, a_1)$ alors

$$\|a\|_p^p = \|a_0\|_p^p + \|a_1\|_p^p.$$

Quelques inégalités

- L'inégalité de Hölder pour $1/p + 1/q = 1$ est: $|a'b| \leq \|a\|_p \|b\|_q$.

Le cas où $p = 1$ et $q = \infty$ est : $|a'b| \leq \|a\|_1 \|b\|_\infty$.

- L'inégalité de Minkowski pour $p \geq 1$ est $\|a + b\| \leq \|a\|_p + \|b\|_q$.
- Les normes p pour $p \geq 1$ satisfont la monotonie des normes, en particulier : $\|a\|_1 \geq \|a\|_2 \geq \|b\|_\infty$.
- En appliquant l'inégalité de Hölder, on a également : $\|a\|_1 = \sum_{j=1}^k |a_j| 1\{a_j \neq 0\} \leq \|a\|_2 \|a\|_0^{1/2}$.

Pour discuter de la régression ridge (régression à la crête) et Lasso, nous utiliserons largement la norme 1 et la norme 2.

4 La régression Ridge

La régression Ridge est un estimateur de type rétrécissement avec des propriétés similaires mais distinctes de celles de l'estimateur de James-Stein. Deux motivations principales sous-tendent l'utilisation de la régression Ridge : réduire la collinéarité entre les variables explicatives et résoudre des problèmes inverses de grande dimension ou mal posés. Lorsque le nombre de variables explicatives p est important, l'estimation des coefficients par les moindres carrés peut être instable en raison du conditionnement faible de $X'X$. Pour pallier ce problème, Hoerl et Kennard (1970) ont proposé l'estimateur Ridge défini comme suit :

$$\hat{\beta}_{ridge} = (X'X + \lambda I_p)^{-1} X'Y$$

où $\lambda > 0$ est un paramètre de rétrécissement. Cet estimateur est bien défini, même lorsque $p > n$, c'est-à-dire lorsque le nombre de variables explicatives dépasse le nombre d'observations. Le paramètre λ joue un rôle clé et doit être sélectionné avec précision.

La constante λ est un paramètre de réglage. Elle garantit la résolution du problème d'inversibilité. En utilisant la décomposition spectrale, on peut écrire $X'X = H'DH$ où H est orthonormé et $D = \text{diag}\{r_1, \dots, r_p\}$ est une matrice diagonale avec les valeurs propres r_j de $X'X$ sur la diagonale. Définissons $\Lambda = \lambda I_p$, on peut écrire :

$$X'X + \lambda I_p = H'DH + \lambda H'H = H'(D + \lambda)H$$

qui a des valeurs propres strictement positives $r_j + \lambda > 0$. Toutes les valeurs propres sont donc bornées par rapport à zéro, de sorte que $X'X + \lambda I_p$ soit de plein rang et bien conditionné.

Une autre perspective moderne repose sur la régularisation. Lorsque $X'X$ est mal conditionnée, son inversion devient problématique. La régularisation, telle que proposée par Tikhonov (1943), consiste à pénaliser les erreurs quadratiques en ajoutant une norme quadratique des coefficients au critère :

$$\text{SSE}_2(\beta, \lambda) = (Y - X\beta)'(Y - X\beta) + \lambda \beta' \beta = \|Y - X\beta\|_2^2 + \lambda \|\beta\|_2^2.$$

Le minimiseur de $\text{SSE}_2(\beta, \lambda)$ est l'estimateur des moindres carrés régularisé (pénalisé) et la condition de premier ordre pour la minimisation est la suivante :

$$-2X'(Y - X\beta) + 2\lambda\beta = 0.$$

L'estimateur des moindres carrés régularisé équivaut à l'estimateur Ridge. La pénalisation par λ empêche les coefficients d'atteindre des valeurs trop grandes ou erratiques, assurant ainsi une solution stable.

La minimisation soumise à une pénalité a une représentation duale sous la forme d'une minimisation sous contrainte :

$$\min_{\beta' \beta \leq \tau} (Y - X\beta)'(Y - X\beta)$$

avec $\tau > 0$. Pour Voir le lien, le Lagrangien du problème contraint est le suivant :

$$\min_{\beta} (Y - X\beta)'(Y - X\beta) + \lambda(\beta' \beta - \tau)$$

où λ est le multiplicateur de lagrange. La condition de première ordre est la même que celle du problème de minimisation soumise à une pénalité.

La différence pratique entre les problèmes de pénalisation et de contrainte est que dans le premier cas, vous spécifiez le paramètre Ridge λ alors que dans le second, vous spécifiez la contrainte τ . Ils sont liés puisque les valeurs λ et de τ satisfont la relation

$$Y'X(X'X + \lambda I_p)^{-1}(X'X + \lambda I_p)^{-1}X'Y = \tau.$$

Il suffit de résoudre (numériquement) l'équation pour trouver λ étant donné τ .




Figure 1: Solution de minimisation doublée de la régression ridge

Pour visualiser le problème des contraintes, voir la figure 1, qui présente un exemple dans $\mathbb{R}^2$. L'ensemble de contraintes $\beta'\beta \leq \tau$ est représenté par la boule autour de l'origine et les ensembles de niveau de la somme des erreurs quadratiques sont affichés sous forme d'ellipses. L'estimateur des moindres carrés est le centre des ellipses, tandis que l'estimateur de la régression ridge est le point du cercle où le contour est tangent. Cela réduit le coefficient des moindres carrés vers le vecteur nulle. Contrairement à l'estimateur de Stein, cependant, il ne rétrécit pas le long du segment de ligne reliant les moindres carrés à l'origine, mais plutôt le long d'une trajectoire déterminée par le degré de corrélation entre les variables. Cette trajectoire est représentée par les lignes pointillées, marquées comme « Ridge path/chemin de Ridge ». Il s'agit de la séquence des coefficients de régression Ridge obtenus lorsque λ varie de 0 à $+\infty$. Lorsque $\lambda = 0$, l'estimateur ridge est égal aux moindres carrés. Pour les petites valeurs de λ , l'estimateur ridge se rapproche légèrement de l'origine en glissant le long de la crête de l'ensemble des contours. Au fur et à mesure que la valeur de λ augmente, l'estimateur ridge prend un chemin plus direct vers l'origine. Ceci est différent de l'estimateur de Stein qui rétrécit l'estimateur des moindres carrés vers l'origine le long du segment de ligne de connexion.

Il est facile de généraliser la régression ridge pour autoriser différentes pénalités sur différents groupes de régresseurs. Prenons le modèle :

$$Y = X_1'\beta_1 + \dots + X_G'\beta_G + e$$

et minimisons le SSE sous contrainte de la pénalité

$$\lambda_1\beta_1'\beta_1 + \dots + \lambda_G\beta_G'\beta_G.$$

La solution est

$$\hat{\beta}_{ridge} = (\mathbf{X}'\mathbf{X} + \Lambda)^{-1} \mathbf{X}'\mathbf{Y}$$

où

$$\Lambda = diag\{\lambda_1 I_{p_1}, \dots, \lambda_G I_{p_G}\}.$$

Cela permet à certains coefficients d'être pénalisés plus (ou moins) que d'autres coefficients. Cette flexibilité supplémentaire se fait au prix de la sélection des paramètres ridges $\lambda = (\lambda_1, \dots, \lambda_G)$. Un cas particulier important est celui de $\lambda_1 = 0$, un groupe de coefficients n'est donc pas pénalisé. Avec $G = 2$, les coefficients sont répartis en deux groupes : pénalisés et non pénalisés.

L'estimateur de régression ridge leave-one-out, les erreurs de prédiction et le critère de validation croisée sont:

$$\begin{aligned}\hat{\beta}_{-i}(\lambda) &= \left(\sum_{j \neq i} X_j X_j' + \Lambda \right)^{-1} \left(\sum_{j \neq i} X_j Y_j \right) \\ \tilde{e}_i(\lambda) &= Y_i - X_i' \hat{\beta}_{-i}(\lambda) \\ CV(\lambda) &= \sum_{i=1}^n \tilde{e}_i(\lambda)^2.\end{aligned}$$

Le paramètre de ridge λ sélectionné par validation croisée, minimise $CV(\lambda)$. L'estimateur de ridge par validation croisée est calculé en utilisant $\hat{\lambda}$.

En pratique, il peut être difficile de minimiser $CV(\lambda)$. Le minimum peut se produire à $\lambda = 0$ (ridge équivaut aux moindres carrés), à $\lambda = +\infty$ (rétrécissement total), ou il peut y avoir plusieurs minima locaux. L'échelle du minimum de λ dépend de l'échelle des régresseurs et, en particulier, des valeurs propres de $X'X$. Il peut être important d'explorer $CV(\lambda)$ pour des valeurs très petites de λ .

Comme pour les moindres carrés, il existe une formule simple pour calculer le critère de validation croisée (**CV**) pour la régression ridge, ce qui accélère considérablement le calcul.

Theorem 29.1 (BH Econ)

La prédiction des erreurs de régression ridge en validation croisée leave-one-out est

$$\tilde{e}_i(\lambda) = \left(1 - X_i' (\mathbf{X}'\mathbf{X} + \Lambda)^{-1} X_i \right)^{-1} \hat{e}_i(\lambda)$$

où $\hat{e}_i(\lambda) = Y_i - X_i' \hat{\beta}_{ridge}$ sont les résidus de la régression ridge.

Une méthode alternative pour la sélection de λ consiste à minimiser le critère de Mallows, qui est égal à

$$C(\lambda) = \sum_{i=1}^n \hat{e}_i(\lambda) + 2\hat{\sigma}^2 \text{tr}((\mathbf{X}'\mathbf{X} + \Lambda)^{-1} (\mathbf{X}'\mathbf{X}))$$

où $\hat{\sigma}^2$ est l'estimateur de la variance issu de l'estimation par les moindres carrés. Le paramètre de ridge $\hat{\lambda}$ sélectionné selon Mallows minimise $C(\lambda)$.

Sous les hypothèses du modèle de régression linéaire, il est simple de calculer le biais exact et la variance de l'estimateur de régression ridge. Considérons le modèle de régression linéaire $Y = X'\beta + e$ avec $E[e | X] = 0$.

Le biais de l'estimateur ridge est :

$$\text{biais} \left[\widehat{\beta}_{ridge} \mid \mathbf{X} \right] = -\lambda (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} \beta.$$

Sous un échantillonnage aléatoire, sa matrice de covariance est :

$$\mathbb{V} \left[\widehat{\beta}_{ridge} \mid \mathbf{X} \right] = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} (\mathbf{X}'\mathbf{D}\mathbf{X}) (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1}$$

où $\mathbf{D} = \text{diag}\{\sigma^2(X_1), \dots, \sigma^2(X_n)\}$ et $\sigma^2(x) = \mathbb{E}[e^2 \mid X]$

Nous pouvons mesurer l'efficacité de l'estimation par la matrice de l'erreur quadratique moyenne (MSE).

$$\text{mse} \left[\widehat{\beta} \mid \mathbf{X} \right] = \mathbb{E} \left[(\widehat{\beta} - \beta)(\widehat{\beta} - \beta)' \mid \mathbf{X} \right].$$

Soit $\underline{\sigma}^2 = \min_{x \in \mathcal{X}} \sigma^2(x)$ où $\mathcal{X}$ est le support de X .

Theorem 29.2 (BH Econ)

Dans le modèle de régression linéaire, si $0 < \lambda < 2\underline{\sigma}^2/\beta'\beta$,

$$\text{mse} \left[\widehat{\beta}_{ridge} \mid \mathbf{X} \right] < \text{mse} \left[\widehat{\beta}_{ols} \mid \mathbf{X} \right].$$

Ce théorème montre que l'estimateur ridge domine l'estimateur des moindres carrés sous certaines conditions. Cela est vrai quelle que soit la dimension de β . Étant donné que la borne supérieure $2\underline{\sigma}^2/\beta'\beta$ est inconnue, il n'est cependant pas clair si une régression ridge réalisable domine les moindres carrés. Cette borne supérieure ne fournit pas de guidance pratique pour la sélection de λ .

Pour l'estimation de la variance de l'estimateur ridge $V_{\widehat{\beta}} = \mathbb{V} \left[\widehat{\beta}_{ridge} \mid \mathbf{X} \right]$ en utilisant l'analogue HC3, on obtient

$$\widetilde{V}_{\widehat{\beta}} = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} \left(\sum_{i=1}^n X_i X_i' \widetilde{e}_i(\lambda)^2 \right) (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1}$$

où $\widetilde{e}_i(\lambda)$ sont les erreurs de prédiction de la régression ridge. Alternativement, les résidus de la régression ridge $\widetilde{e}_i(\lambda)$ peuvent être utilisés, mais il n'est pas clair comment appliquer une correction appropriée des degrés de liberté. En présence de regroupement (clustering) ou de dépendance sérielle, le composant central de $\widetilde{V}_{\widehat{\beta}}$ peut être modifié comme d'habitude. Si les régresseurs sont hautement clairsemés (comme dans une régression avec variables indicatrices clairsemées), il peut être prudent d'utiliser l'estimateur homoscédastique

$$\widetilde{V}_{\widehat{\beta}}^0 = \widetilde{\sigma}_i^2(\lambda) (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} (\mathbf{X}'\mathbf{X}) (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1}$$

avec $\widetilde{\sigma}_i^2(\lambda) = n^{-1} \sum_{i=1}^n \widetilde{e}_i(\lambda)^2$.

Étant donné que l'estimateur ridge est explicitement biaisé, des préoccupations naturelles se posent quant à l'interprétation des erreurs standard calculées à partir de ces estimateurs de matrice de covariance. Les intervalles de confiance calculés de la manière habituelle auront une couverture insuffisante en raison du biais. Une solution consiste à interpréter l'estimateur ridge et ses erreurs standard de manière similaire à celles obtenues en régression non paramétrique. Les estimateurs et les intervalles de confiance sont valides pour les projections pseudo-vraies, Ex: $\beta^* = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}'\mathbf{X}\beta$. C'est la même interprétation que nous utilisons pour le modèle de projection et pour la régression non paramétrique. Pour une inférence asymptotiquement exacte sur les vrais coefficients, le paramètre ridge λ pourrait être sélectionné de manière à satisfaire $\lambda = o(\sqrt{n})$ de manière analogue à une bande passante de sous-lissage en régression non paramétrique.




Figure 2: Estimation des rendements de l'expérience par les moindres carrés et la régression ridge

5 La régression Lasso

Dans la section précédente, nous avons appris que la régression ridge minimise la somme des erreurs quadratiques plus une pénalité en *norme 2* sur le vecteur des coefficients. La sélection de modèle (Ex: le critère de Mallows) minimise la somme des erreurs quadratiques plus une pénalité en *norme 0* (le nombre de coefficients non nuls). Un cas intermédiaire utilise la pénalité en *norme 1*. Cette approche a été proposée par Tibshirani (1996) et est connue sous le nom de **Lasso (Least Absolute Shrinkage and Selection Operator)**. Le critère des moindres carrés avec une pénalité en *norme 1* est

$$\text{SSE}_1(\beta, \lambda) = (Y - X\beta)'(Y - X\beta) + \lambda \sum_{j=1}^p |\beta_j| = \|Y - X\beta\|_2^2 + \lambda \|\beta\|_1^2.$$

L'estimateur Lasso est le minimiseur de cette fonction

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} \text{SSE}_1(\beta, \lambda).$$

À l'exception de cas particuliers, la solution doit être trouvée numériquement. Heureusement, les algorithmes de calcul sont étonnamment simples et rapides. Une propriété importante est que lorsque $\lambda > 0$, l'estimateur Lasso est bien défini même si $p > n$.

Le problème de minimisation du Lasso possède un problème de minimisation dual sous contrainte.

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\|\beta\|_1 \leq \tau} \text{SSE}_1(\beta, \lambda).$$

Pour voir que les deux problèmes sont équivalents, observons que le problème de minimisation sous contrainte a pour lagrangien

$$\min_{\beta} (Y - X\beta)'(Y - X\beta) + \lambda \left(\sum_{j=1}^p |\beta_j| - \tau \right)$$

qui possède des conditions du premier ordre :

$$-2X_j'(Y - X\beta) + \text{sgn}(\beta_j) = 0$$

Cela est identique aux conditions de minimisation du critère pénalisé. Ainsi, les solutions sont les mêmes.




Figure 3: Solution de minimisation duale du Lasso

L'ensemble de contraintes $\{\|\beta\|_1 \leq \tau\}$ pour le problème dual est un polytope croisé ressemblant à un diamant multifacetté. Le problème de minimisation dans $\mathbb{R}^2$ est illustré dans la figure ci-dessous. Les ensembles de contours de la somme des erreurs quadratiques sont des ellipses avec la solution des moindres carrés au centre. L'ensemble de contraintes est le polytope ombré. L'estimateur Lasso est le point d'intersection entre l'ensemble de contraintes et la plus grande ellipse tracée. Dans cet exemple, il touche un sommet de l'ensemble de contraintes et donc l'estimateur contraint fixe $\beta_1 = 0$.

Ceci est un résultat typique dans l'estimation Lasso. Comme nous minimisons un problème quadratique sous une contrainte de polytope, la solution tend à se trouver aux sommets, ce qui élimine un sous-ensemble des coefficients.

Le chemin de Lasso est tracé avec une ligne en pointillés. Il représente la séquence des solutions obtenues lorsque l'ensemble de contraintes varie. Le chemin de solution possède la propriété d'être une ligne droite allant de l'estimateur des moindres carrés à l'axe des ordonnées (dans cet exemple), où β_2 est annulé. Ensuite, le chemin de solution suit l'axe des ordonnées jusqu'à l'origine.

En général, le chemin de solution est linéaire par segments jusqu'à ce qu'un coefficient atteigne zéro, auquel cas ce coefficient est éliminé. Dans cet exemple particulier, le chemin de solution montre que β_2 augmente tandis que β_1 diminue. Ainsi, bien que Lasso soit un estimateur de rétrécissement, il ne réduit pas les coefficients individuellement de manière monotone.

Il est instructif de comparer les figures 1 et 3 qui ont les mêmes contours de somme des carrés. L'estimateur ridge est généralement une solution intérieure, avec aucun coefficient individuel fixé à zéro, tandis que l'estimateur Lasso fixe typiquement certains coefficients à zéro. Cependant, les deux estimateurs suivent des chemins de solution similaires, suivant le "ridge" du critère SSE plutôt que de prendre un chemin direct vers l'origine.

Un cas où nous pouvons calculer explicitement les estimations Lasso est lorsque les régresseurs sont orthogonaux. Supposons que $X'X = I_p$. Alors, la condition du premier ordre pour la minimisation se simplifie en

$$-2 \left(\hat{\beta}_{ols,j} - \hat{\beta}_{Lasso,j} \right) + \lambda \text{sgn}(\hat{\beta}_{Lasso,j}) = 0$$

qui a la solution explicite

$$\hat{\beta}_{\text{Lasso},j} = \begin{cases} \hat{\beta}_{\text{ols},j} - \lambda/2 & \text{si } \hat{\beta}_{\text{ols},j} > \lambda/2 \\ 0 & \text{si } |\hat{\beta}_{\text{ols},j}| \leq \lambda/2 \\ \hat{\beta}_{\text{ols},j} + \lambda/2 & \text{si } \hat{\beta}_{\text{ols},j} < -\lambda/2. \end{cases}$$

Cette estimation Lasso est une transformation continue de l'estimation des moindres carrés. Pour de petites valeurs de l'estimation des moindres carrés, l'estimation Lasso est fixée à zéro. Pour toutes les autres valeurs, l'estimation Lasso rapproche l'estimation des moindres carrés de zéro par un facteur $\lambda/2$.

Les estimateurs Lasso et ridge sont des fonctions continues. Tout comme la régression ridge, le Lasso n'est pas invariant à l'échelle des régresseurs. Si l'on redimensionne un régresseur, la pénalité prend un sens différent. Il est donc important de standardiser les régresseurs de manière appropriée avant d'appliquer le Lasso. Il est courant de mettre à l'échelle toutes les variables pour qu'elles aient une moyenne nulle et une variance unitaire.

Le Lasso n'est également pas invariant aux rotations des régresseurs. Par exemple, le Lasso sur (X_1, X_2) n'est pas le même que le Lasso sur $(X_1 - X_2, X_2)$ bien qu'ils aient des solutions des moindres carrés identiques. Cela est problématique car typiquement il n'existe pas de spécification par défaut.

Critiquement important pour l'estimation Lasso, il y a la pénalité λ . Lorsque λ est proche de zéro, les estimations sont proches des moindres carrés. À mesure que λ augmente, le nombre de variables sélectionnées diminue. Le choix de λ induit un compromis entre la complexité et la parcimonie.

Il est courant dans la littérature statistique de voir les coefficients tracés en fonction de λ . Cela peut être utilisé pour visualiser le compromis entre la parcimonie et l'inclusion des variables. Cela ne fournit toutefois pas une règle statistique pour la sélection.

La méthode de sélection la plus courante est la minimisation de la validation croisée en K plis (voir la section 28.9). La validation croisée “leave-one-out” (LOO) n'est pas typiquement utilisée car elle est coûteuse en termes de calcul. De nombreux programmes définissent le nombre de plis par défaut comme $K = 10$, bien que certains auteurs utilisent $K = 5$, tandis que d'autres recommandent $K = 20$.

La validation croisée en K plis est un estimateur de l'erreur quadratique moyenne de prévision hors échantillon. Par conséquent, la sélection de la pénalité par minimisation du critère K -fold vise à sélectionner des modèles avec une bonne précision de prévision, mais pas nécessairement pour d'autres objectifs comme une inférence précise.

Conformément à la convention, la valeur de λ sélectionnée par la CV est celle qui minimise le critère CV. Un autre choix populaire est la règle “1se”, qui sélectionne λ correspondant à la valeur qui donne le modèle le plus parcimonieux parmi les valeurs dans un écart-type de la valeur minimale. L'idée est de sélectionner un modèle similaire, mais plus parcimonieux que le choix minimisant la CV.

La validation croisée en K plis est mise en œuvre en divisant d'abord aléatoirement les observations en K groupes. Par conséquent, le critère CV est sensible à l'ordonnancement aléatoire. Il est donc prudent de définir la graine du nombre aléatoire pour la reproductibilité et d'évaluer la sensibilité à travers les semences initiales. En général, sélectionner une valeur plus grande pour K réduit cette sensibilité.

La consistance asymptotique de la sélection par CV pour l'estimation Lasso a été démontrée par Chetverikov, Liao, et Chernozhukov (2020).

6 Elastic Net

La différence entre la régression Lasso et la régression Ridge est que le Lasso utilise la pénalité de norme 1, tandis que Ridge utilise la pénalité de norme 2. Étant donné que ces deux méthodes ont chacune des avantages, il semble raisonnable de rechercher des améliorations supplémentaires en trouvant un compromis.

En prenant une moyenne pondérée des pénalités, on obtient le critère **Elastic Net** :

$$\text{SSE}(\beta, \lambda, \alpha) = (Y - X\beta)'(Y - X\beta) + \lambda (\alpha \|\beta\|_2^2 + (1 - \alpha) \|\beta\|_1)$$

avec un poids α tel que $0 \leq \alpha \leq 1$. Cela inclut le Lasso ($\alpha = 0$) et la régression Ridge ($\alpha = 1$) comme cas particuliers.

Pour de petites valeurs positives de α , les ensembles de contraintes ressemblent à des versions « arrondies » des ensembles de contraintes du Lasso.

En général, les paramètres (α, λ) sont sélectionnés par minimisation conjointe du critère de validation croisée en K groupes. Comme la pénalité Elastic Net est une combinaison linéaire-quadratique, la solution est **computationnellement similaire** à celle du Lasso.

7 Post-Lasso

L'estimateur **Lasso** sélectionne simultanément les variables et réduit les coefficients. Cette réduction introduit un biais dans l'estimation. Ce biais peut être réduit en appliquant la méthode des **moindres carrés après la sélection par Lasso**. Cela est connu sous le nom d'**estimateur Post-Lasso**.

La procédure se déroule en **deux étapes** :

1. Estimer le modèle $Y = X\beta + e$ par **Lasso**. Soit X_S l'ensemble des variables de X ayant des coefficients non nuls dans Lasso, et β_S les coefficients correspondants.
2. Estimer les coefficients β_S par **moindres carrés** :

$$\hat{\beta}_S = (X_S' X_S)^{-1} X_S' Y$$

avec X_S l'ensemble des variables dans X qui ont des coefficients non nuls dans $\hat{\beta}_{\text{Lasso}}$. Cet estimateur est appelé **estimateur des moindres carrés Post-Lasso**.

Belloni et Chernozhukov (2013) ont fourni des conditions sous lesquelles l'estimateur Post-Lasso **converge au même taux** que l'estimateur Lasso.

L'estimateur **Post-Lasso** est un **estimateur de sélection post-modèle** ou un estimateur à **seuil dur**. En effet, lorsque les **régressions sont orthogonales**, l'estimateur Post-Lasso **équivalent exactement** à un estimateur de sélection, transformant les coefficients estimés par moindres carrés à l'aide d'une **fonction de seuil dur**.

8 Arbres de régression

Les arbres de régression ont été introduits par **Breiman, Friedman, Olshen et Stone (1984)** et sont également connus sous l'acronyme **CART** (*Classification and Regression Trees*). Un arbre de régression est une méthode **non paramétrique** utilisant un grand nombre de **fonctions en escalier**. L'idée est qu'avec un nombre suffisant de **points de séparation**, une fonction en escalier peut **approximer n'importe quelle fonction**. Les arbres de régression peuvent être particulièrement utiles lorsqu'il y a une **combinaison de régresseurs continus et discrets**, rendant les méthodes traditionnelles de noyaux et de séries difficiles à appliquer.

Les arbres de régression peuvent être vus comme **des splines d'ordre 0 avec des nœuds libres**. Ils sont également similaires aux **modèles de régression à seuil** contenant uniquement des **intercepts** (sans coefficients de pente) et un très grand nombre de seuils.

L'objectif est d'estimer la fonction de régression conditionnelle :

$$m(x) = \mathbb{E}[Y|X = x]$$

où Y est une variable scalaire et X un vecteur de régresseurs. Les éléments de X peuvent être **continus, binaires ou ordinaux**. Si un régresseur est **catégorique**, il doit d'abord être **transformé en un ensemble de variables binaires**.

Métaphore de l'arbre

La littérature sur les arbres de régression utilise un **vocabulaire inspiré des arbres vivants** :

1. **Un sous-échantillon** est une **branche**.
2. **Les branches terminales** sont des **nœuds** ou **feuilles**.
3. **Ajouter des branches** est appelé **faire croître un arbre**.
4. Réduire le nombre de branches, c'est élaguer un arbre.

L'algorithme de base commence par une seule branche. Faites croître un arbre de grande taille en divisant les branches de manière séquentielle. Ensuite, élaguez-le en utilisant un critère d'information. L'objectif de la phase de croissance est de développer un arbre déterminé par les données et ayant un faible biais d'estimation. L'élagage est une application de la régression pas à pas en sens inverse (*backward stepwise regression*), dont le but est de réduire la sur-paramétrisation et la variance d'estimation.

L'algorithme des arbres de régression fait un usage intensif de l'algorithme de séparation d'échantillons en régression. Il s'agit d'une version simplifiée de la régression à seuil (Section 23.7 Bruce Hansen Eco.). La méthode utilise la régression non linéaire des moindres carrés (*NLLS*) pour estimer le modèle.

$$Y = \hat{\theta}_1 1_{\{X_d \leq \gamma\}} + \hat{\theta}_2 1_{\{X_d > \gamma\}} + e$$
$$\mathbb{E}[e | X] = 0$$

avec l'indice d et le paramètre γ comme paramètres libres. Le critère NLLS est minimisé sur (d, θ) par une recherche sur grille. Les estimations produisent une séparation d'échantillon. L'algorithme des arbres de régression applique une séparation séquentielle des échantillons pour effectuer un grand nombre de divisions, chacune sur un sous-échantillon d'observations.

L'algorithme de croissance de base est le suivant. Les observations sont $\{Y_i, X_{1i}, \dots, X_{ki} : i = 1, \dots, n\}$.

1. Sélectionner une taille minimale de nœud $N_{\min}$ (par exemple 5). C'est le nombre minimal d'observations dans chaque feuille.
2. Appliquer séquentiellement les séparations d'échantillons de régression.
 - (a) Appliquer l'algorithme de séparation d'échantillons de régression pour diviser chaque branche en deux sous-branches, chacune ayant une taille d'au moins $N_{\min}$.
 - (b) Sur chaque sous-branche b :
 - i. Calculer la moyenne empirique $\bar{b}$ de Y_i pour les observations de la sous-branche.
 - ii. Ceci est l'estimateur de la fonction de régression sur cette sous-branche.
 - iii. Les résidus sur la sous-branche sont $e_i = Y_i - \bar{b}$.
 - (c) Sélectionner la branche dont la division réduit le plus la somme des erreurs quadratiques.
 - (d) Diviser cette branche en deux branches. Ne faire aucune autre division.
 - (e) Répéter les étapes (a)-(d) jusqu'à ce qu'aucune branche ne puisse être divisée davantage. Les branches terminales (non divisées) sont les feuilles.

Après l'exécution de l'algorithme de croissance, la régression estimée est une fonction en escalier multidimensionnelle avec un grand nombre de branches et de feuilles.

L'algorithme de réduction (pruning) de base est le suivant :

1. Définir le critère d'information de type Mallows :

$$C = \sum_{i=1}^n \hat{e}_i^2 + \alpha N$$

où N est le nombre de feuilles et α est un paramètre de pénalisation.

2. Calculer le critère C pour l'arbre actuel.
3. Appliquer une régression pas à pas (backward stepwise regression) pour réduire le nombre de feuilles.
 - (a) Identifier la feuille dont la suppression diminue le plus C .
 - (b) Tailler (supprimer) cette feuille.
 - (c) Si aucune feuille ne réduit C lorsqu'elle est supprimée, arrêter la réduction.
 - (d) Sinon, répéter les étapes (a)-(c).

Le paramètre de pénalité est généralement sélectionné par validation croisée en K plis. Le critère de type Mallows est utilisé en raison de sa simplicité, mais, à ma connaissance, il ne possède pas de fondement théorique pour la sélection de la pénalité dans les arbres de régression.

L'avantage des arbres de régression est qu'ils offrent une approximation non paramétrique très flexible. Leur principale utilisation est la prédiction. Un inconvénient des arbres de régression est que les résultats sont difficiles à interpréter, car il n'y a pas de coefficients de régression. Un autre inconvénient est que la régression ajustée $m(x)$ est une fonction en escalier discrète, ce qui peut être une approximation grossière lorsque $m(x)$ est continue et lisse. Pour obtenir une bonne approximation, un arbre de régression peut nécessiter un grand nombre de feuilles, ce qui peut entraîner un modèle non parcimonieux avec une variance d'estimation élevée.

La distribution d'échantillonnage des arbres de régression est difficile à établir, en partie à cause de la forte corrélation entre le placement des divisions d'échantillon et les moyennes estimées. Ceci est similaire aux problèmes associés à la sélection de modèle a posteriori (voir sections 28.16 et 28.17). Une méthode qui brise cette dépendance est la proposition de l'arbre honnête (honest tree) de Wager et Athey (2018). L'échantillon est divisé en deux moitiés, A et B . L'échantillon A est utilisé pour placer les divisions et l'échantillon B pour effectuer l'estimation au sein des feuilles. Bien que cela réduise l'efficacité de l'estimation (l'échantillon est effectivement divisé par deux), la moyenne conditionnelle estimée ne sera pas biaisée par la corrélation entre les divisions estimées et les moyennes.

Les algorithmes d'arbres de régression sont implémentés dans le package R **rpart**.

9 Bagging

Le bagging (*bootstrap aggregating*) a été introduit par Breiman (1996) comme une méthode pour réduire la variance d'un prédicteur. Nous nous concentrons ici sur son utilisation pour l'estimation d'une moyenne conditionnelle. L'idée de base est simple : générer un grand nombre B d'échantillons bootstrap, estimer le modèle de régression sur chaque échantillon bootstrap, puis prendre la moyenne des estimations de régression obtenues. La moyenne des estimations bootstrap constitue l'*estimateur par bagging de la moyenne conditionnelle*.

Le bagging est considéré comme utile lorsque l'estimateur de la moyenne conditionnelle présente un faible biais mais une forte variance. Cela se produit notamment pour les estimateurs avec seuils durs (*hard thresholding*), tels que les arbres de régression, les modèles de sélection et le post-Lasso. Le bagging agit comme une opération de lissage qui réduit la variance, ce qui peut conduire à un estimateur par bagging ayant une erreur quadratique moyenne (*MSE*) plus faible. Cependant, il est généralement considéré comme moins utile pour les estimateurs présentant un biais élevé, car il pourrait amplifier ce biais.

Nous décrivons d'abord l'algorithme d'estimation. Soit $m(x) = \mathbb{E}[Y|X = x]$ la moyenne conditionnelle et $\hat{m}(x)$ un estimateur, tel qu'un arbre de régression. Soit $\hat{m}_b^*(x)$ le même estimateur construit sur un échantillon bootstrap. L'estimateur par bagging de $m(x)$ est donné par :

$$\hat{m}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{m}_b^*(x).$$

Lorsque B augmente, cet estimateur converge en probabilité bootstrap vers l'estimateur idéal par bagging $\mathbb{E}[\hat{m}^*(x)]$.

Supposons que l'estimateur par bagging soit construit en utilisant le bootstrap paramétrique $\hat{\theta}^* \sim N(\hat{\theta}, 1)$. L'estimateur de sélection bootstrap est alors $\hat{\theta}_{\text{pms}}^* = h(\hat{\theta}^*)$. Il en résulte que l'estimateur par bagging est donné par :

$$\hat{\theta}_{\text{bag}} = \mathbb{E}[\hat{\theta}_{\text{pms}}^*] = \mathbb{E}[h(\hat{\theta}^*)] = g(\hat{\theta}).$$

Ainsi, tandis que l'estimateur de sélection $\hat{\theta}_{\text{pms}} = h(\hat{\theta})$ est la transformation en seuil dur $h(t)$ appliquée à $\hat{\theta}$, l'estimateur par bagging $\hat{\theta}_{\text{bag}} = g(\hat{\theta})$ est la transformation lissée $g(t)$ appliquée à $\hat{\theta}$.

Bühlmann et Yu (2002) soutiennent que les transformations lissées ont généralement une variance plus faible que les transformations à seuil dur. Par conséquent, ils affirment que $\hat{\theta}_{\text{bag}}$ aura généralement une variance plus faible que $\hat{\theta}_{\text{pms}}$.

L'application la plus courante du bagging concerne les arbres de régression. Les arbres ont une structure similaire à notre estimateur de sélection $\hat{\theta}_{\text{pms}}$ et devraient donc entraîner une réduction similaire de la variance d'estimation et de l'erreur quadratique moyenne (MSE) par rapport à l'estimation par arbre de régression.

Un sous-produit pratique du bagging est un proxy de validation croisée appelé erreur de prédiction hors échantillon (**out-of-bag**, **OOB**). Un échantillon bootstrap non paramétrique typique contient environ 63% des observations initiales, ce qui signifie qu'environ 37% des observations ne sont pas présentes dans cet échantillon bootstrap. Ainsi, une estimation bootstrap de la fonction de régression $m(x)$ construite sur cet échantillon a "laissé de côté" environ 37% des observations. Ce qui signifie que des erreurs de prédiction valables peuvent être calculées sur ces observations « exclues ». Alternativement, pour toute observation i , parmi les B échantillons bootstrap, environ $0.63B$ contiendront cette observation et environ $0.37B$ ne l'incluront pas. L'estimateur « leave i out » du bagging, $\hat{m}_{-i}(x)$, de $m(x)$ est obtenu en moyennant uniquement sur ce second ensemble (les 37% qui excluent l'observation). L'erreur hors échantillon est alors $\tilde{e}_i = Y_i - \hat{m}_{-i}(X_i)$. Le critère de validation croisée hors échantillon est $\sum_{i=1}^n \tilde{e}_i^2$. Celui-ci peut être utilisé comme estimateur de l'erreur quadratique moyenne de prévision hors échantillon (MSFE) et pour comparer et sélectionner des modèles.

Wager, Hastie et Efron (2014) proposent des estimateurs de $V_n(x) = \text{var}(\hat{m}_{\text{bag}}(x))$. Soit N_{ib} le nombre de fois où l'observation i apparaît dans l'échantillon bootstrap b , et $N_i = \frac{1}{B} \sum_{b=1}^B N_{ib}$. L'estimateur **jackknife infinitésimal** (EJI) de V_n est donné par

$$\hat{V}_n(x) = \sum_{i=1}^n \text{cov}^*(N_i, \hat{m}_{\text{bag}}(x))^2 = \sum_{i=1}^n \left[\frac{1}{B} \sum_{b=1}^B (N_{ib} - N_i)(m_b(x) - m_{\text{bag}}(x)) \right]^2. \quad (\text{EJI})$$

Cet estimateur de variance est basé sur Efron (2014).

Alors que la proposition de Breiman et la plupart des applications du bagging sont mises en œuvre en utilisant le bootstrap non paramétrique, une alternative consiste à utiliser le sous-échantillonnage. Un estimateur basé sur le sous-échantillonnage repose sur un échantillonnage sans remplacement plutôt qu’avec remplacement, comme dans le bootstrap conventionnel. Des échantillons de taille $s < n$ sont prélevés à partir de l’échantillon initial et utilisés pour construire l’estimateur $\hat{m}_b^*(x)$. Pour le reste, les méthodes sont identiques. Il s’avère qu’il est plus simple de développer une théorie de la distribution pour le bagging sous l’hypothèse de sous-échantillonnage. Ainsi, cette hypothèse est fréquemment employée dans les traitements théoriques.

10 Forêts aléatoires

Les forêts aléatoires, introduites par Breiman (2001), sont une modification des arbres de régression avec bagging. Cette modification vise à réduire la variance de l’estimation. Les forêts aléatoires sont populaires dans les applications de Machine Learning et ont largement remplacé les arbres de régression simples.

Considérons l’application du bagging aux arbres de régression. Comme les échantillons bootstrap sont similaires entre eux, les arbres de régression issus du bootstrap auront également tendance à être similaires, notamment en ce qu’ils effectuent souvent des divisions basées sur les mêmes variables. Cela signifie que, conditionnellement à l’échantillon, les arbres de régression issus du bootstrap sont positivement corrélés. Cette corrélation entraîne une variance élevée de la moyenne des arbres bootstrap, même lorsque le nombre de répétitions bootstrap B est grand. La modification apportée par les forêts aléatoires consiste à *décorréliser* les arbres de régression bootstrap en introduisant une **randomisation supplémentaire**. Cette décorrélisation réduit la variance de la moyenne bootstrap et, par conséquent, son erreur quadratique moyenne (MSE).

L’algorithme de base des forêts aléatoires est le suivant (les valeurs par défaut recommandées proviennent de la description de Hastie, Tibshirani et Friedman, 2008) :

1. Choisissez une taille minimale de feuille $N_{\min}$ (par défaut 5), une fraction minimale de division, $\alpha \in [0, 1)$, et un nombre d’échantillonnage m parmi p (par défaut $p/3$).
2. Pour $b = 1, \dots, B$:
 - (a) Tirer un échantillon bootstrap non paramétrique.
 - (b) Faire croître un arbre de régression sur cet échantillon bootstrap en suivant ces étapes :
 - i. Sélectionner m variables aléatoirement parmi les p régresseurs.
 - ii. Parmi ces m variables, choisir celle qui produit la meilleure division pour la régression, en s’assurant que chaque sous-échantillon après la division contient au moins $N_{\min}$ observations et représente une fraction minimale d’observations de la branche.
 - iii. Diviser l’échantillon bootstrap en conséquence.
 - (c) Arrêter lorsque chaque feuille contient entre $N_{\min}$ et $2N_{\min} - 1$ observations.
- (d) Définir $\hat{m}_b(x)$ comme la moyenne empirique de Y sur chaque feuille de l’arbre bootstrap.
3. Calculer $\hat{m}_{\text{rf}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{m}_b(x)$.

L'utilisation de la randomisation pour réduire le nombre de variables de p à m à chaque étape modifie la structure de l'arbre, ce qui réduit la corrélation entre les arbres de régression issus du bootstrap. Cette réduction de la corrélation diminue la variance de la moyenne bootstrap.

L'estimateur du jackknife infinitésimal (EJI) peut être utilisé pour estimer la variance et l'erreur standard, comme discuté par Wager, Hastie et Efron (2014).

Bien que les forêts aléatoires soient populaires dans les applications, une théorie distributionnelle a mis du temps à se développer. Certains résultats récents ont progressé en se concentrant sur des forêts aléatoires générées par sous-échantillonnage plutôt que par bootstrap.

Une variante proposée par Wager et Athey (2018) consiste à utiliser des **arbres "honnêtes"** pour supprimer la dépendance entre les divisions de l'échantillon et les moyennes d'échantillon.

La consistance et la normalité asymptotique ont été établies par Wager et Athey (2018). Ils supposent que la moyenne conditionnelle et la variance sont continues de Lipschitz en x , que $X \sim U[0, 1]^p$ et que p est fixé. Ils supposent également que la forêt aléatoire est construite par sous-échantillonnage, estimée à l'aide d'arbres honnêtes, et que la fraction minimale de division satisfait $0 < \alpha \leq 0.2$.

Sous ces conditions, ils établissent que, ponctuellement en x ,

$$\frac{\hat{m}_{\text{rf}}(x) - m(x)}{\sqrt{V_n(x)}} \xrightarrow{d} \mathcal{N}(0, 1),$$

pour une séquence de variance $V_n(x) \rightarrow 0$. Ces résultats justifient l'inférence pour l'estimation par forêt aléatoire de la fonction de régression et le calcul des erreurs standard. La distribution asymptotique ne contient pas de biais, indiquant que l'estimateur est sous-lissé.

Les conditions de Wager-Athey pour la normalité asymptotique sont étonnamment faibles. Cependant, la théorie ne donne pas d'indications sur la vitesse de convergence de l'estimateur. L'idée essentielle du résultat est la suivante : l'algorithme de division et les restrictions garantissent que l'espace des régresseurs est (en un sens approximatif) divisé uniformément en $N \approx n^\alpha$ feuilles qui croissent à un taux puissance. Cela garantit que l'estimateur est asymptotiquement non biaisé, et avec un contrôle adéquat du biais au carré, celui-ci peut être rendu inférieur à la variance. L'hypothèse $0 < \lambda$ garantit que le nombre d'observations par feuille augmente avec n , ce qui, combiné avec la construction d'arbres honnêtes, assure la normalité asymptotique de l'estimateur.

De plus, Wager et Athey (2018) affirment (mais ne prouvent pas) que la variance $V_n(x)$ peut être estimée de manière consistante à l'aide du jackknife infinitésimal (EJI), au sens où $\frac{\hat{V}_n(x)}{V_n(x)} \xrightarrow{P} 1$.

11 Assemblage

L'**assemblage** est le terme utilisé en Machine learning pour désigner l'**agrégation de modèles** à travers plusieurs algorithmes de Machine learning. L'assemblage est populaire dans les applications pratiques du Machine Learning.

Supposons que vous disposiez d'un ensemble d'estimateurs (par exemple, sélection par validation croisée, rétrécissement de James-Stein, JMA, SBIC, ACP, régression à noyau, régression en séries, régression ridge, Lasso, arbre de régression, arbre de régression baggé et forêt aléatoire). Lequel devriez-vous utiliser ? Il est raisonnable de s'attendre à ce qu'une méthode fonctionne bien avec certains types de données, tandis que d'autres méthodes soient plus adaptées à d'autres types de données. Le principe de l'**agrégation de modèles** suggère qu'il est possible d'obtenir de meilleures performances en prenant une moyenne pondérée plutôt qu'en sélectionnant un seul modèle.

L'**assemblage** en Machine learning peut utiliser bon nombre de ces mêmes méthodes. Une méthode populaire, appelée **stacking**, est identique à l'**agrégation de modèles Jackknife**. Cette méthode sélectionne

les poids d'agrégation des modèles en minimisant un critère de validation croisée, sous la contrainte que les poids soient non négatifs et que leur somme soit égale à un.

Malheureusement, la littérature théorique sur l'assemblage reste limitée. Une grande partie des recommandations concernant les méthodes spécifiques repose sur leurs performances empiriques.

12 Double Sélection Lasso

L'inférence post-estimation est difficile avec la plupart des estimateurs de Machine Learning. Par exemple, considérons l'estimateur post-Lasso (moindres carrés appliqués aux régresseurs sélectionnés par le Lasso). Il s'agit d'un estimateur post-sélection de modèle (PMS). La probabilité de couverture des intervalles de confiance standards appliqués aux estimateurs PMS peut être très éloignée du niveau nominal.

Considérons le modèle linéaire :

$$\begin{aligned} Y &= D\theta + X'\beta + e \\ \mathbb{E}[e \mid D, X] &= 0 \end{aligned} \tag{1}$$

où Y et D sont scalaires et X est un vecteur de dimension $p \times 1$. La variable D est l'objet principal de l'étude, tandis que X représente les variables de contrôle. L'objectif est d'inférer sur θ .

Si on estime ce modèle par post-Lasso en ne pénalisant que β , on sélectionne les variables de X et on réalise une régression des moindres carrés de Y sur D et les variables sélectionnées de X .

Belloni, Chernozhukov et Hansen (2014b) montrent qu'une meilleure précision de la couverture peut être obtenue si X est inclus dans la régression (1) dès lors qu'il est corrélé à D . Cela conduit à la stratégie dite de **double sélection**. On commence par spécifier une équation auxiliaire pour D :

$$\begin{aligned} D &= X'\gamma + V \\ \mathbb{E}[V \mid X] &= 0 \end{aligned} \tag{2}$$

En substituant (2) dans (1), on obtient une forme réduite pour Y :

$$\begin{aligned} Y &= X'\eta + U \\ \mathbb{E}[U \mid X] &= 0 \end{aligned} \tag{3}$$

où $\eta = \beta + \gamma\theta$ et $U = e + V\theta$

L'algorithme de double sélection proposé applique la sélection de modèle (par exemple, la sélection par Lasso) séparément aux équations (2) et (3), prend l'union des régresseurs sélectionnés, puis estime l'équation (1) par moindres carrés en utilisant ces régresseurs. Cette méthode garantit qu'une variable X est incluse si elle est pertinente pour la régression (1) ou si elle est corrélée avec D .

L'algorithme **double-selection** recommandé par Belloni, Chernozhukov et Hansen (2014b) suit ces étapes :

1. Estimer l'équation auxiliaire (2) par Lasso et noter X_1 les variables sélectionnées.
2. Estimer l'équation réduite (3) par Lasso et noter X_2 les variables sélectionnées.
3. Définir $\tilde{X} = X_1 \cup X_2$, soit l'union des variables sélectionnées dans les deux équations.

4. Réaliser une régression de Y sur $(D, \tilde{X})$ pour obtenir l'estimateur **double-selection** $\hat{\theta}_{DS}$.
5. Calculer une erreur standard robuste à l'hétéroscédasticité pour $\hat{\theta}_{DS}$.

Belloni, Chernozhukov et Hansen (2014b) montrent que sous une structure de parcimonie approximative (où les relations de régression sont bien approchées par un ensemble fini de régresseurs), l'estimateur $\hat{\theta}_{DS}$ est **asymptotiquement normal**, et son **t-ratio** suit une loi normale standard, ce qui valide les méthodes d'inférence conventionnelles.

L'idée clé est que la sélection via Lasso dans les deux équations garantit que toutes les variables pertinentes sont incluses, évitant ainsi le biais de sélection. L'avantage principal de l'estimateur de double sélection réside dans sa simplicité et sa structure intuitive claire.

13 Post régularisation Lasso

Une amélioration potentielle du Lasso à double sélection est l'estimateur de Lasso post-régularisation proposé par Chernozhukov, Hansen et Spindler (2015), qui est désigné sous le nom de “partialing-out Lasso” dans le manuel Stata. Cet estimateur est essentiellement le même que celui de Robinson (1988) pour le modèle partiellement linéaire, mais estimé par Lasso plutôt que par régression par noyau.

Nous commençons par transformer l'équation structurelle (1) afin d'éliminer la composante de grande dimension. Prenons l'espérance de (1) conditionnellement à X et soustrayons-la de chaque côté. Cela conduit à l'équation :

$$Y - \mathbb{E}[Y | X] = (D - \mathbb{E}[D | X])\theta + e.$$

On remarque que cette transformation élimine le régresseur X ainsi que le coefficient de grande dimension β . Les modèles (2) et (3) spécifient $\mathbb{E}[Y | X]$ et $\mathbb{E}[D | X]$ comme des fonctions linéaires de X . En substituant ces expressions, nous obtenons :

$$Y - X'\eta = (D - X'\gamma)\theta + e. \tag{4}$$

Si η et γ étaient connus, le coefficient θ pourrait être estimé par moindres carrés. Comme η et γ sont inconnus, ils doivent être estimés. Chernozhukov, Hansen et Spindler (2015) recommandent de les estimer par Lasso ou post-Lasso, séparément pour Y et D .

L'estimateur recommandé par Chernozhukov, Hansen et Spindler (2015) est le suivant :

1. **Estimation de (2) par Lasso ou post-Lasso** avec le paramètre de Lasso λ_1 . Soit $\hat{\gamma}$ l'estimateur des coefficients et $\hat{V}_i = D_i - X_i'\hat{\gamma}$ le résidu.
2. **Estimation de (3) par Lasso ou post-Lasso** avec le paramètre de Lasso λ_2 . Soit $\hat{\eta}$ l'estimateur des coefficients et $\hat{U}_i = Y_i - X_i'\hat{\eta}$ le résidu.
3. **Estimation finale** : Soit $\hat{\theta}_{PR}$ le coefficient des moindres carrés ordinaires (OLS) de la régression de $\hat{U}$ sur $\hat{V}$.
4. **Calcul de l'erreur standard** : Une erreur standard conventionnelle (hétéroscédastique) est calculée pour $\hat{\theta}_{PR}$.

Chernozhukov, Hansen et Spindler (2015) introduisent un raisonnement expliquant pourquoi $\hat{\theta}_{PR}$ peut être relativement insensible à la sélection de modèle a posteriori. L'inférence est invalidée par la sélection de modèle lorsque D et X sont corrélés, car la condition de moment pour θ devient sensible à β .

En particulier, la condition de moment pour θ , basée sur l'équation (1), est :

$$m(\theta, \beta) = \mathbb{E}[D(Y - D\theta - X'\beta)] = 0.$$

Sa sensibilité par rapport à β est donnée par sa dérivée évaluée aux vrais coefficients.

$$\frac{\partial}{\partial \beta} m(\theta, \beta) = -\mathbb{E}[DX']$$

Ce qui est non nul lorsque D et X sont corrélés. Cela signifie que l'inclusion ou l'exclusion de la variable X a un impact sur la condition de moment pour θ et donc sur sa solution.

En revanche, la condition de moment pour θ basée sur l'équation (4) est :

$$\begin{aligned} m_{PR}(\theta, \beta) &= \mathbb{E}[(D - X'\gamma)(Y - X'\eta - (D - X'\gamma)\theta)] \\ m_{PR}(\theta, \beta) &= \mathbb{E}[(D - X'\gamma)(Y - D\theta - X'\beta)]. \end{aligned}$$

Sa sensibilité par rapport à β est :

$$\frac{\partial}{\partial \beta} m_{PR}(\theta, \beta) = -\mathbb{E}[(D - X'\gamma)X'] = -\mathbb{E}[VX'] = 0.$$

Cela est égal à zéro car V est une erreur de régression, comme spécifié dans (2), et est donc non corrélé avec X .

Puisque la sensibilité de $m_{PR}(\theta, \beta)$ par rapport à β est nulle, l'inclusion ou l'exclusion de la variable X a seulement un impact faible sur la condition de moment pour μ et sur son estimateur.

Sous des hypothèses données, on a le résultat suivant:

$$\sqrt{n}(\hat{\theta}_{PR} - \theta) \xrightarrow{d} N\left(0, \frac{\mathbb{E}[V^2 e^2]}{\mathbb{E}[V^2]^2}\right).$$

De plus, l'estimateur de variance standard pour $\hat{\theta}_{PR}$ est convergent pour la variance asymptotique.

L'avantage de l'estimateur post-régularisation $\hat{\theta}_{PR}$ par rapport à l'estimateur à double sélection $\hat{\theta}_{DS}$ est *l'efficacité*. L'estimateur post-régularisation utilise uniquement les composantes pertinentes de X pour centrer séparément Y et D , ce qui conduit à une plus grande parcimonie. Différentes composantes de X peuvent être pertinentes pour D et Y .

L'estimateur post-régularisation permet de distinguer ces effets et de les estimer séparément. En revanche, l'estimateur à double sélection utilise l'union des deux ensembles de régresseurs pour estimer θ , ce qui entraîne une spécification *moins parcimonieuse*.

En conséquence, *un avantage* de l'estimateur à double sélection est *la réduction du biais et une meilleure robustesse*. Sur le plan théorique, la dérivation de la théorie asymptotique pour l'estimateur post-régularisation est *considérablement plus simple* que pour l'estimateur à double sélection, car elle repose uniquement sur la manipulation des vitesses de convergence. En revanche, l'estimateur à double sélection nécessite une gestion plus minutieuse de l'union des ensembles de régresseurs.

14 Machine learning double/différencié

La contribution la plus récente aux méthodes d'inférence pour le modèle (1) est l'estimateur **Double/Debiased Machine Learning (DML)** de Chernozhukov, Chetverikov, Demirer, Duflo, Hansen,

Newey et Robins (2018). Notre description se concentrera sur la régression linéaire estimée par Lasso, bien que leur approche soit beaucoup plus générale.

Cette méthode d'estimation a suscité un grand intérêt parmi les économètres ces dernières années et est considérée comme **l'une des méthodes d'estimation les plus avancées**.

L'estimateur **DML** étend l'estimateur de *post-régularisation* présenté dans la section précédente en ajoutant une *technique de partitionnement des échantillons*, similaire à l'estimateur *IV à échantillons séparés*. Les auteurs soutiennent que cela *réduit la dépendance entre les étapes d'estimation* et peut *améliorer les performances*.

Comme présenté dans la section précédente, l'estimateur de post-régularisation commence par estimer les coefficients des modèles (2) et (3), puis estime le coefficient θ . L'estimateur **à échantillons séparés** effectue ces étapes d'estimation en utilisant **des échantillons distincts**.

L'estimateur **DML** va encore plus loin en utilisant une *partition en K sous-échantillons* (*K-fold partitioning*). L'algorithme d'estimation est le suivant.

1. Diviser aléatoirement l'échantillon en K sous-échantillons indépendants $A_k, k = 1, \dots, K$, d'environ même taille n/K .
2. Écrire les matrices de données pour chaque sous-échantillon sous la forme (Y_k, D_k, X_k) .
3. Pour chaque $k = 1, \dots, K$:
 - a) Utiliser toutes les observations sauf celles du sous-échantillon k pour estimer les coefficients θ et γ dans les équations (2) et (4) à l'aide de *Lasso* ou *post-Lasso*. Ces estimateurs exclus du pli k sont notés $\hat{\gamma}_{-k}$ et $\hat{\eta}_{-k}$.
 - b) Calculer $\hat{V}_k = D_k - X_k \hat{\gamma}_{-k}$ et $\hat{U}_k = Y_k - X_k \hat{\eta}_{-k}$. Ces valeurs sont les résidus estimés V et U pour les observations du sous-échantillon k en utilisant les estimateurs exclus du pli.
4. Estimer $\hat{\theta}_{\text{DML}}$ selon la formule :

$$\hat{\theta}_{\text{DML}} = \left(\sum_{k=1}^K \hat{V}_k' \hat{V}_k \right)^{-1} \left(\sum_{k=1}^K \hat{V}_k' \hat{U}_k \right)$$

Où équivalamment, empiler $\hat{V}^k$ et $\hat{U}^k$ en vecteurs de taille $n \times 1$, V et U , et définir :

$$\hat{\theta}_{\text{DML}} = (\hat{V}' \hat{V})^{-1} (\hat{V}' \hat{U})$$

5. Construire une erreur standard classique (hétéroscédastique) pour $\hat{\theta}_{\text{DML}}$.

De plus, l'estimateur standard de la variance de $\hat{\theta}_{\text{DML}}$ est **convergent** pour la variance asymptotique.

L'avantage de l'estimateur DML par rapport à l'estimateur post-régularisation est que la séparation de l'échantillon élimine la dépendance entre les deux étapes d'estimation, réduisant ainsi le biais lié à la sélection post-modèle. Cependant, cette procédure présente plusieurs inconvénients.

Tout d'abord, l'estimateur est aléatoire en raison de la séparation de l'échantillon. Deux chercheurs travaillant avec le même ensemble de données, mais effectuant des séparations aléatoires différentes, obtiendront deux estimateurs distincts. Cette arbitrarité peut être perturbante. Cette variabilité peut être réduite en choisissant une valeur plus grande de K , mais cela augmente le coût de calcul.

Un autre inconvénient de la séparation de l'échantillon est que l'estimation de γ et η est effectuée sur des échantillons plus petits, ce qui réduit l'efficacité de l'estimation. Cependant, cet effet reste mineur si $K \geq 10$.

Quoi qu'il en soit, ces considérations suggèrent que le DML peut être particulièrement approprié dans des contextes où n est grand et $K \geq 10$.

Au début de cette section, l'estimateur DML a été décrit comme l'« état de l'art ». Ce domaine évolue rapidement, de sorte que cet estimateur spécifique pourrait bientôt être dépassé par une nouvelle itération.

15 liste de package

- Régression ridge : *glmnet package*
- Lasso : *glmnet package*
- Elastic Net : *glmnet package*
- Arbre de régressio : *rpart package*
- Forêt aléatoire : *randomForest package*
- Double sélection Lasso: *hdm package*

16 Appendice

<i>Function class $\mathcal{F}$ (and its parametrization)</i>	<i>Regularizer $R(f)$</i>
Global/parametric predictors	
Linear $\beta'x$ (and generalizations)	Subset selection $ \beta _0 = \sum_{j=1}^k 1_{\beta_j \neq 0}$ LASSO $ \beta _1 = \sum_{j=1}^k \beta_j $ Ridge $ \beta _2^2 = \sum_{j=1}^k \beta_j^2$ Elastic net $\alpha \beta _1 + (1 - \alpha) \beta _2^2$
Local/nonparametric predictors	
Decision/regression trees	Depth, number of nodes/leaves, minimal leaf size, information gain at splits
Random forest (linear combination of trees)	Number of trees, number of variables used in each tree, size of bootstrap sample, complexity of trees (see above)
Nearest neighbors	Number of neighbors
Kernel regression	Kernel bandwidth
Mixed predictors	
Deep learning, neural nets, convolutional neural networks	Number of levels, number of neurons per level, connectivity between neurons
Splines	Number of knots, order
Combined predictors	
Bagging: unweighted average of predictors from bootstrap draws	Number of draws, size of bootstrap samples (and individual regularization parameters)
Boosting: linear combination of predictions of residual	Learning rate, number of iterations (and individual regularization parameters)
Ensemble: weighted combination of different predictors	Ensemble weights (and individual regularization parameters)

Figure 4: Récapitulatif des méthodes de Machine Learning

17 Références

- 1). Charpentier, A., Flachaire, E. & Ly, A. (2018). Econometrics and Machine Learning. *Economie et Statistique / Economics and Statistics*, 505-506, 147–169.
- 2). Hansen, B. E. (2022). Econometrics. Madison, WI: University of Wisconsin.
- 3). Kevin P. Murphy. (2012). Machine Learning: A probabilistic Perspective: Massachusetts Institute of Technology.
- 4). Victor Chernozhukov, Christian Hansen, Martin Spindler. Valid Post-Selection and Post-Regularization Inference: An Elementary, General Approach. *Annual Review of Economics*, Vol. 7: 649-688 (August 2015). arXiv:1501.03430
- 5). Belloni, A. and Chernozhukov, V. (2013). Least Squares After Model Selection in High-dimensional Sparse Models, *Bernoulli* 19(2), 521-547. ArXiv, 2009.
- 6). Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey & Robins (2018). Double/Debiased Machine Learning for Treatment and Causal Parameters, arXiv:1608.00060 (2024)